Machine Learning and Data Processing

a.a. 2024-2025

Big Data in a Nutshell

Prof. Ing. F. Benedetto

francesco.benedetto@uniroma3.it
fbenedetto@ieee.org

Chair of "Machine Learning and Data Processing" – University of Roma Tre
Chair of the "Definitions and Concepts for Dynamic Spectrum Access" - IEEE 1900.1

©SP4TE Lab 2017

How they talk of Big Data

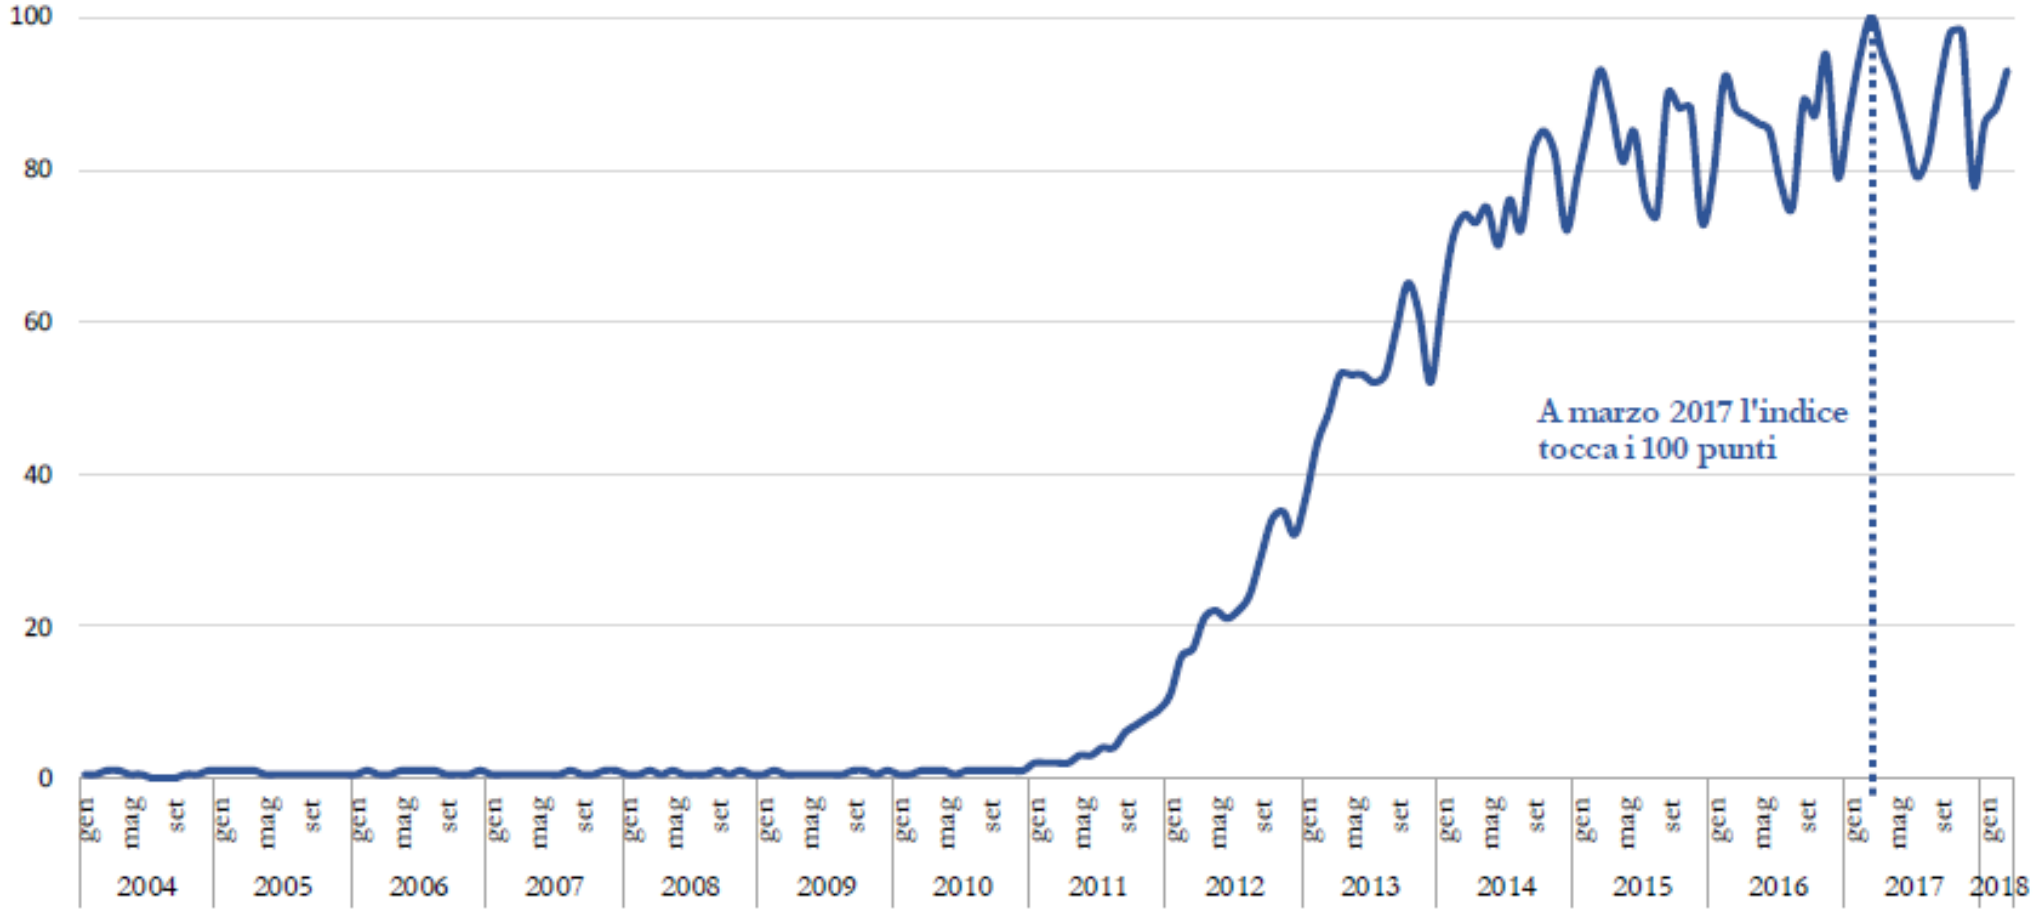

Google trends*: andamento del termine "big data" nel motore di ricerca di *Google

Fonte: elaborazione Agcom su dati *Google.trends*

The Big Data Challenge

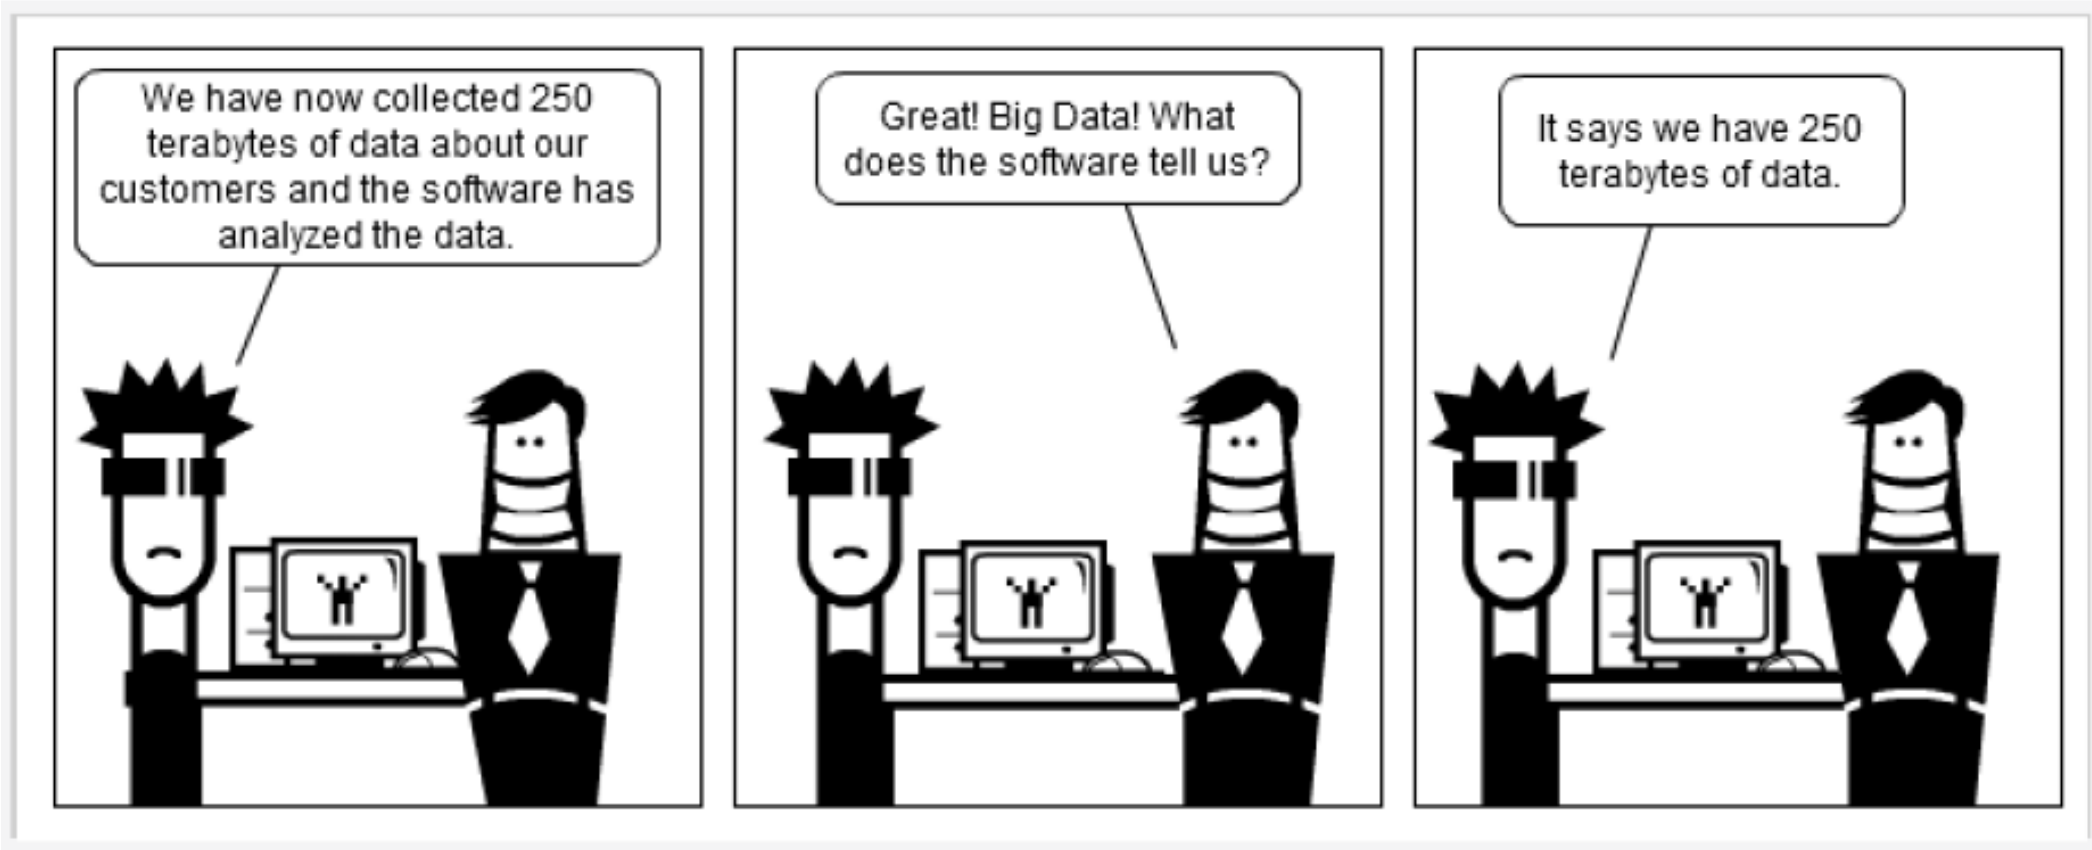

"The big data Challenge"

Sean R. Nicholson
www.socmedsean.com

Big Data: volume, diversity, and speed

- I big data rappresentano il fattore produttivo chiave in un'economia data-driven; molti sono gli ambiti, sia privati che pubblici, in cui l'utilizzo di tecniche di analisi di big data ha permesso di creare nuovi servizi, migliorare quelli esistenti, innovare i processi produttivi e distributivi, rendere l'offerta di tutti i prodotti e servizi (anche non digitali) più rispondenti alle esigenze di consumatori e cittadini.

- I big data fanno riferimento a un salto di paradigma interpretativo della realtà economica e sociale attraverso tecniche di analisi (data mining) eseguite su enormi quantità di dati (volume), caratterizzati da formati assai differenti (varietà), immagazzinati ed elaborati a un ritmo (velocità) sempre più rapido (spesso in tempo reale).

- Volume, varietà e velocità dei big data

Big Data: a change of paradigm

Processo di radicale riconsiderazione ed evoluzione degli approcci tradizionali all'analisi dei dati che, anche in conseguenza dei progressi tecnologici, necessitano di un nuovo paradigma interpretativo.

- Uso di campioni poco numerosi
- Uso di "*dead data*" (trend passati per prevedere il futuro)
- Uso di dati strutturati
- Necessità di minimizzazione gli errori (uso di modelli di regressione)
- Ricerca di nessi di causalità (domanda di ricerca: perchè?)

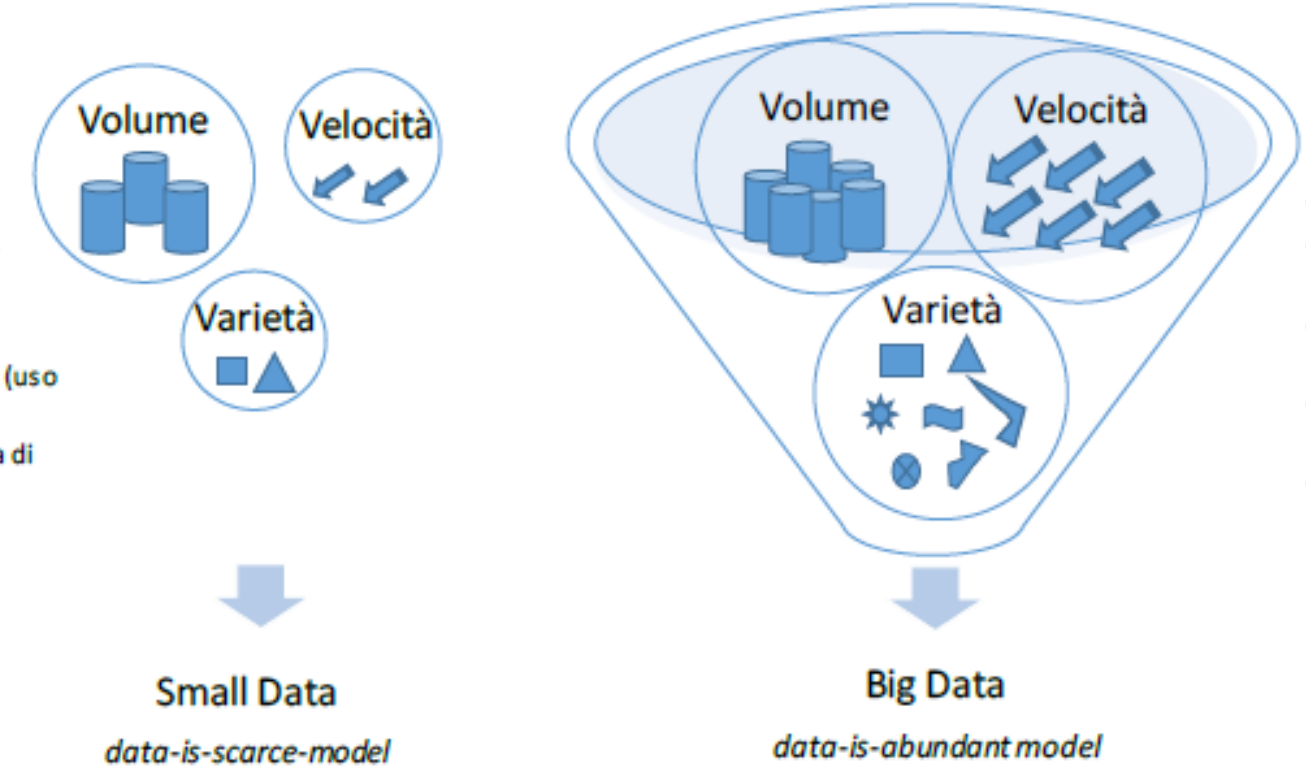

- Uso di campioni estesi / interi universi
- Uso di "*real time data*" (utilizzo dei flussi di dati in tempo reale)
- Uso di dati strutturati, non strutturati e semi strutturati
- Caos e complessità (data lake, utilizzo di algoritmi complessi, machine learning)
- Ricerca di correlazioni (domanda di ricerca: cosa fare?)

Il cambio di paradigma con l'avvento dei big data

Fonte: elaborazione Agcom

Big Data: 3-V approach

L'approccio 3-V

Il valore dei dati è nettamente superiore a quello derivante dal primo utilizzo -> *data driven economy*.

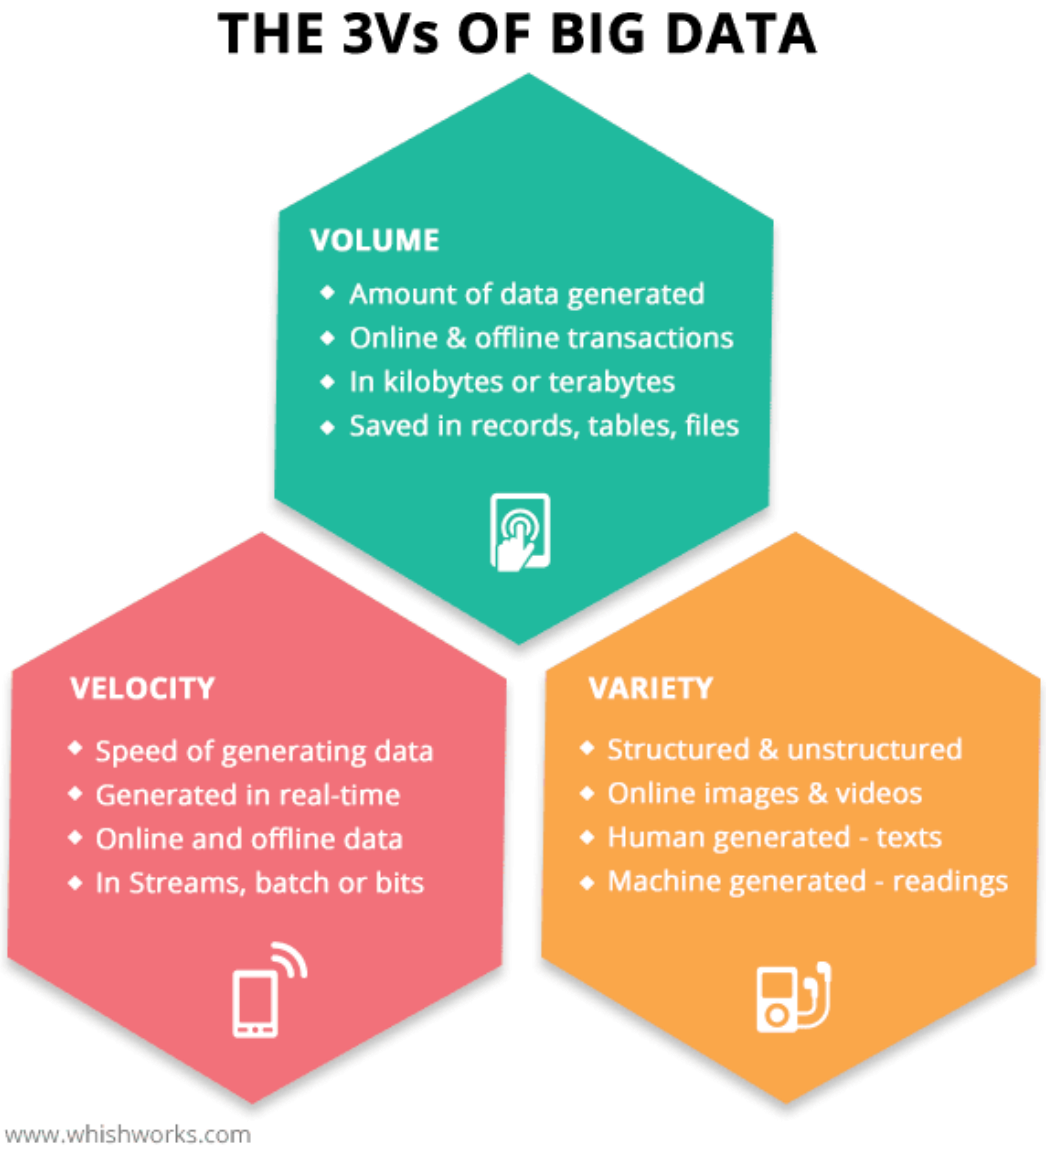

Big Data: the datasphere

Vi è la necessità quindi di trattare dati che contemporaneamente presentano, con un'intensità senza precedenti, caratteristiche che rendono le architetture tradizionali obsolete ed inidonee -> *data analytics*.

Il volume dei Big Data: la Datasphere

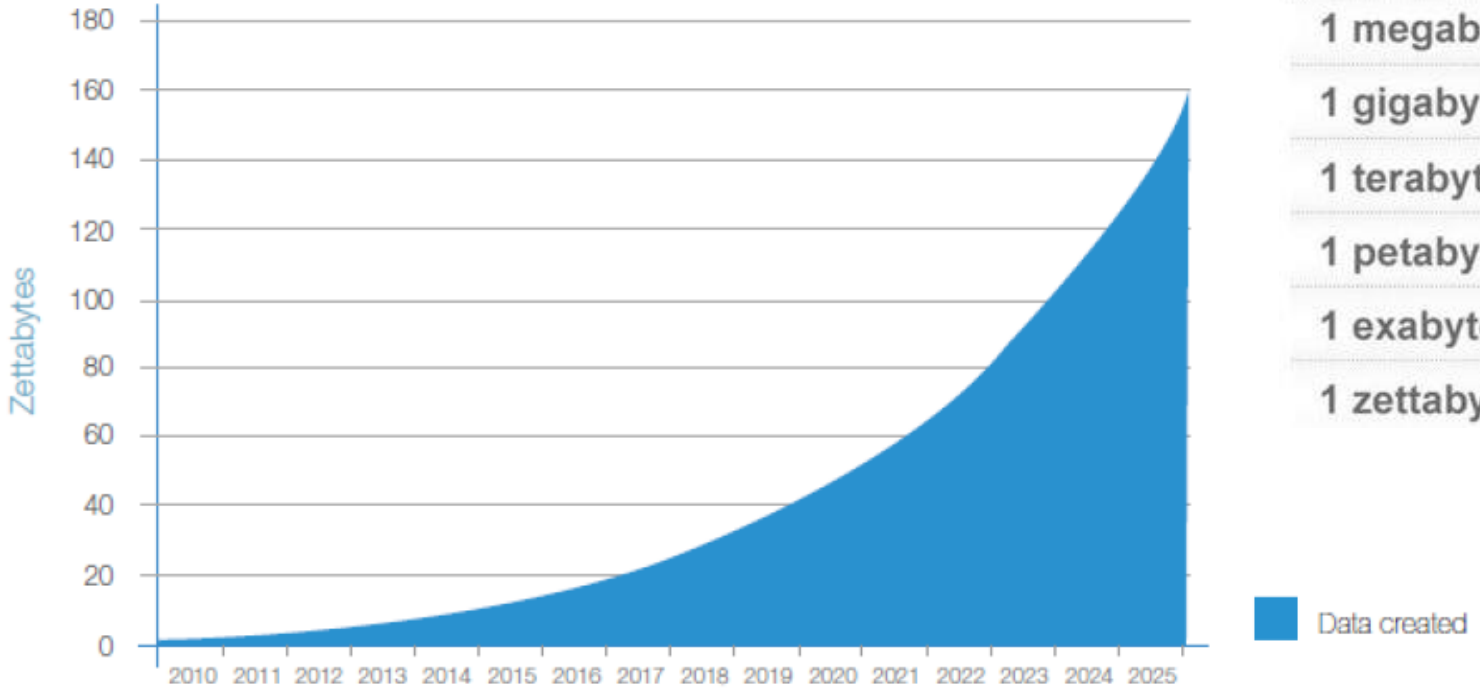

La crescita della *datasphere* (in zettabyte)
Fonte: IDC Data Age 2025 – Aprile 2017

WHAT'S A ZETTABYTE?

1 kilobyte	1,000
1 megabyte	1,000,000
1 gigabyte	1,000,000,000
1 terabyte	1,000,000,000,000
1 petabyte	1,000,000,000,000,000
1 exabyte	1,000,000,000,000,000,000
1 zettabyte	1,000,000,000,000,000,000,000

Zettabyte -> 36000 anni di video HD, ovvero una pila di 250 miliardi di DVD.

The diversity of Big Data

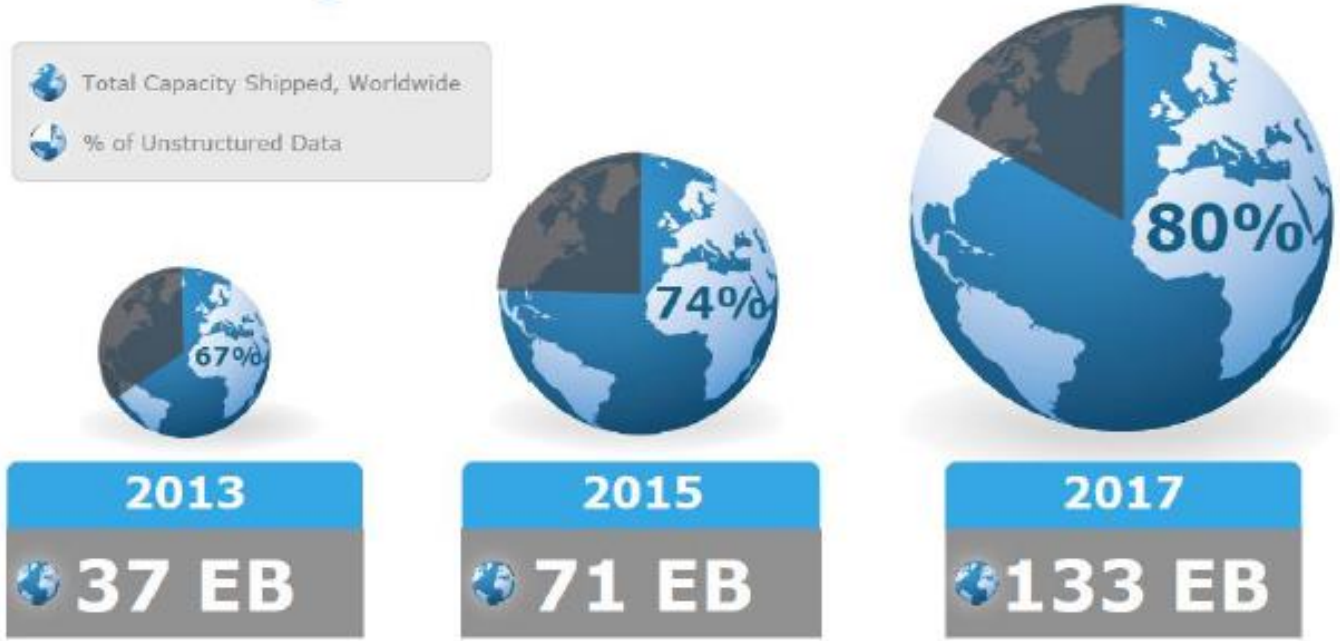

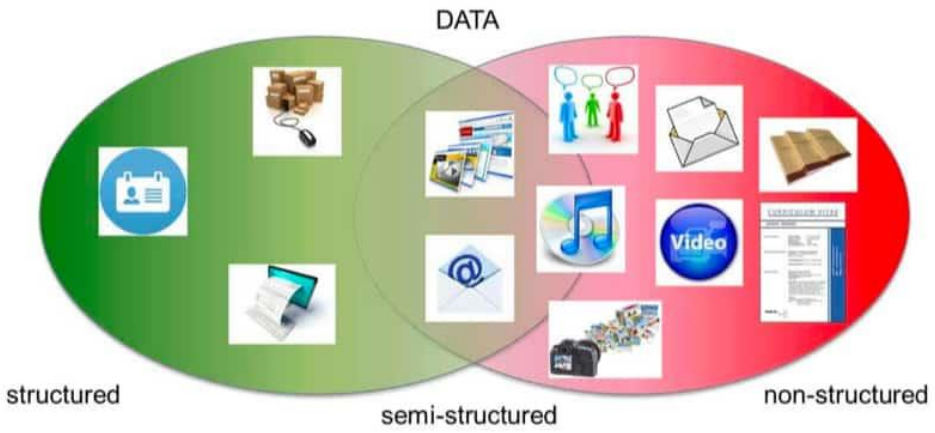

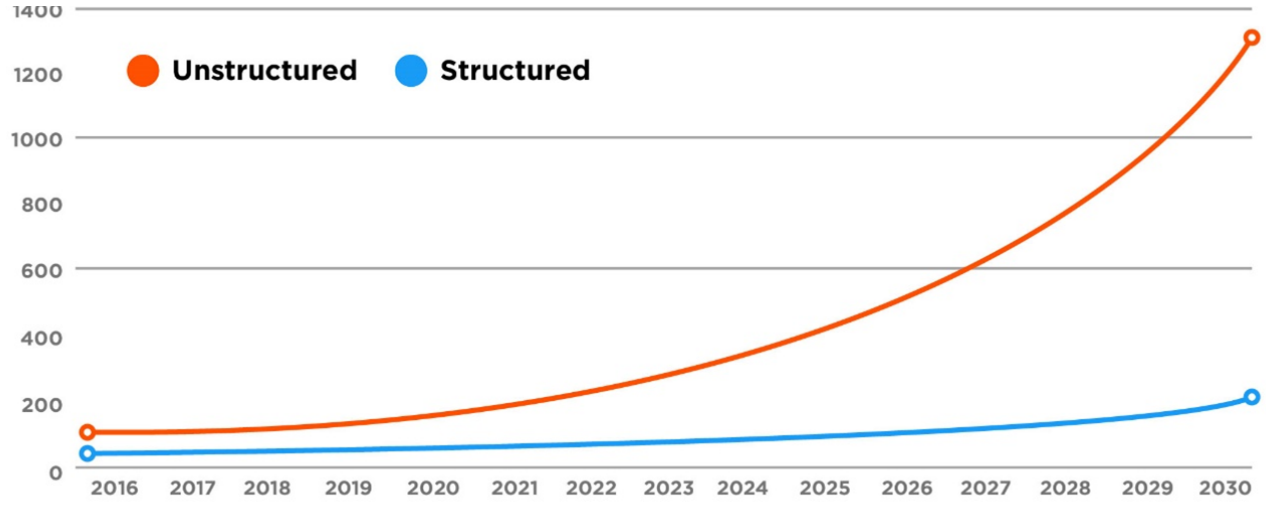

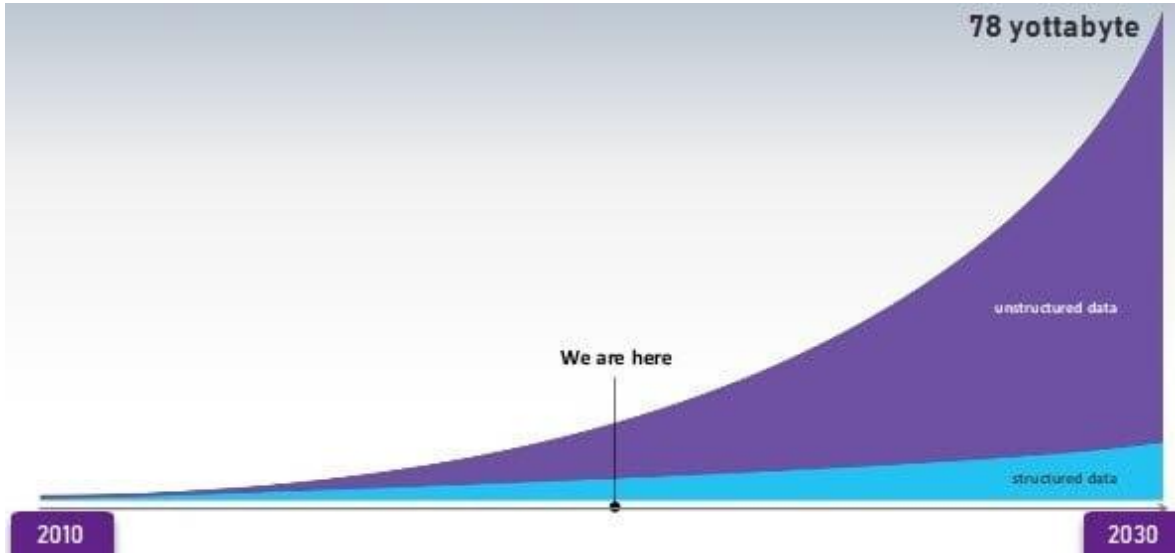

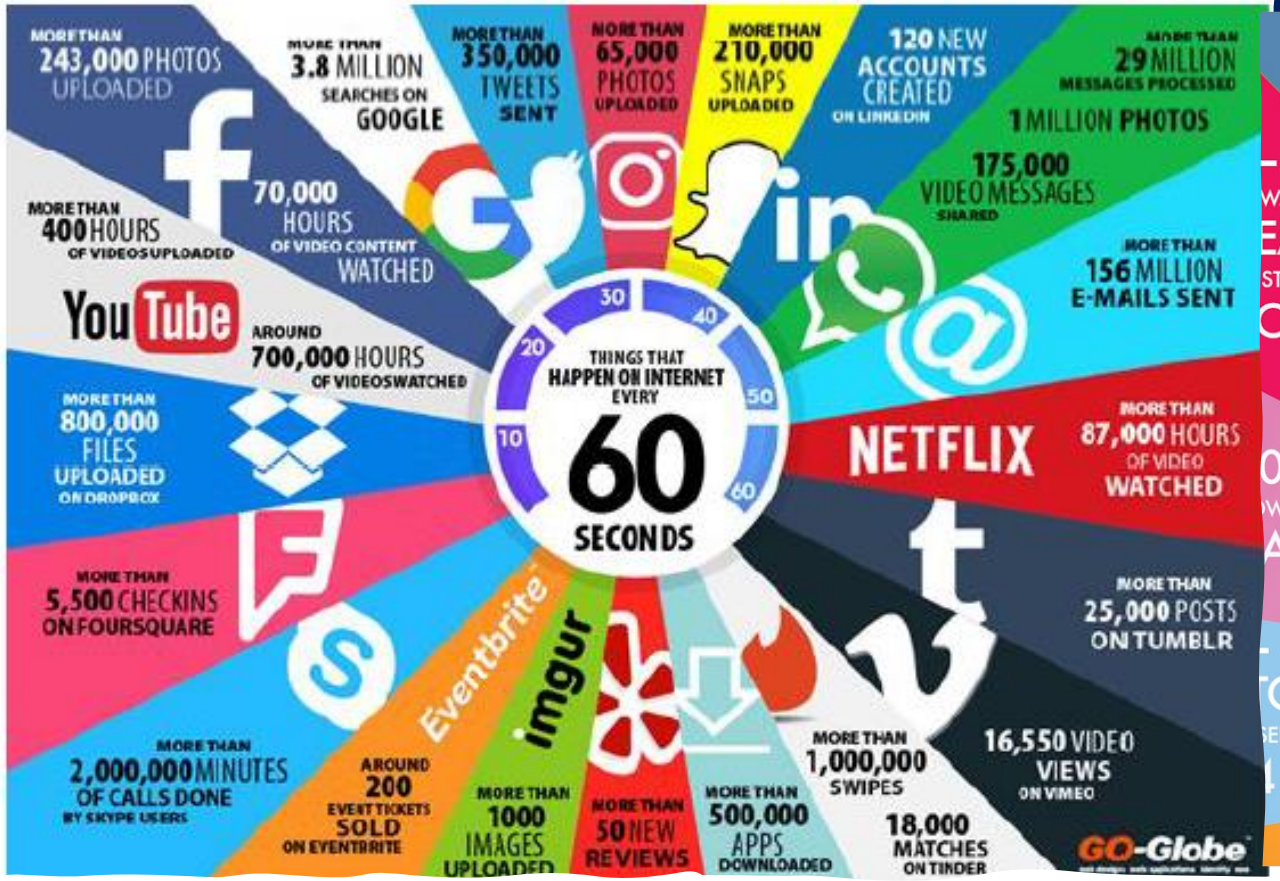

La velocità dei Big Data

2017

2024

Big Data: the 6-V approach

L'approccio 6-V

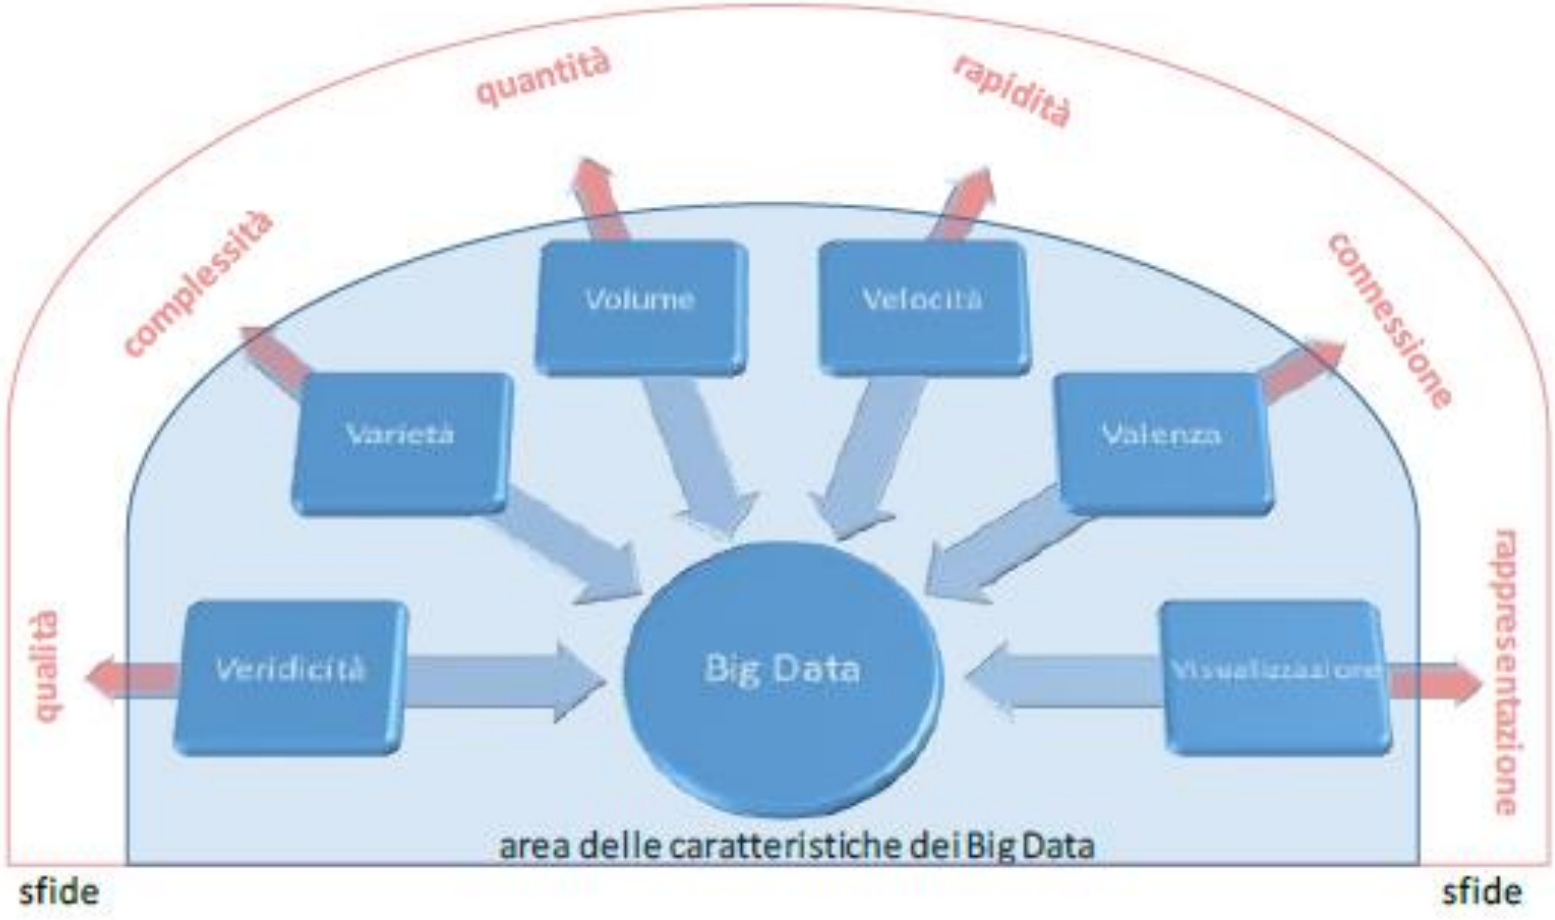

Veridicità: rilevanza degli aspetti qualitativi legati ai dati e alla fiducia che in essi si può riporre.

Valenza: più un dato è connesso con altri dati, maggiore è la sua valenza.

Visualizzazione: importanza dell'estrarre informazioni sintetiche da una vastità di dati.

Big Data: Data Science Process

Data Science Process

La catena del valore: dal momento della raccolta a quello dell'utilizzo, i dati passano attraverso varie fasi tra loro indipendenti che via via ne accrescono il valore.

Il dato inizia a trasformarsi in **informazione.**

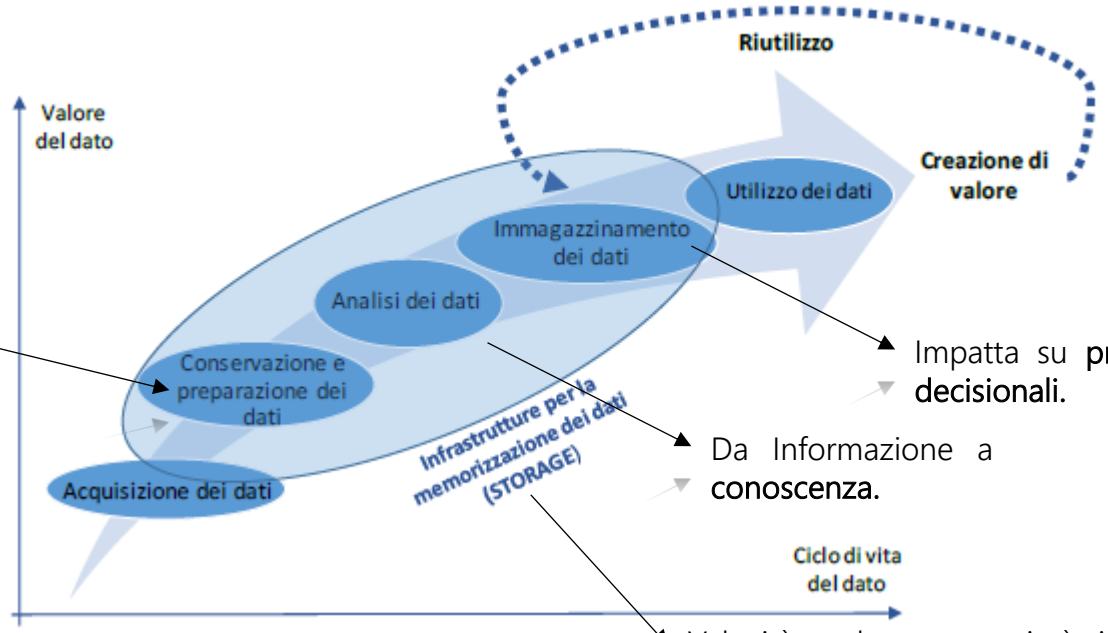

Impatta su **processi decisionali.**

Da Informazione a **conoscenza.**

Velocità, volume e varietà impattano sulla **scelta delle infrastrutture.**

Big Data: impatto trasversale

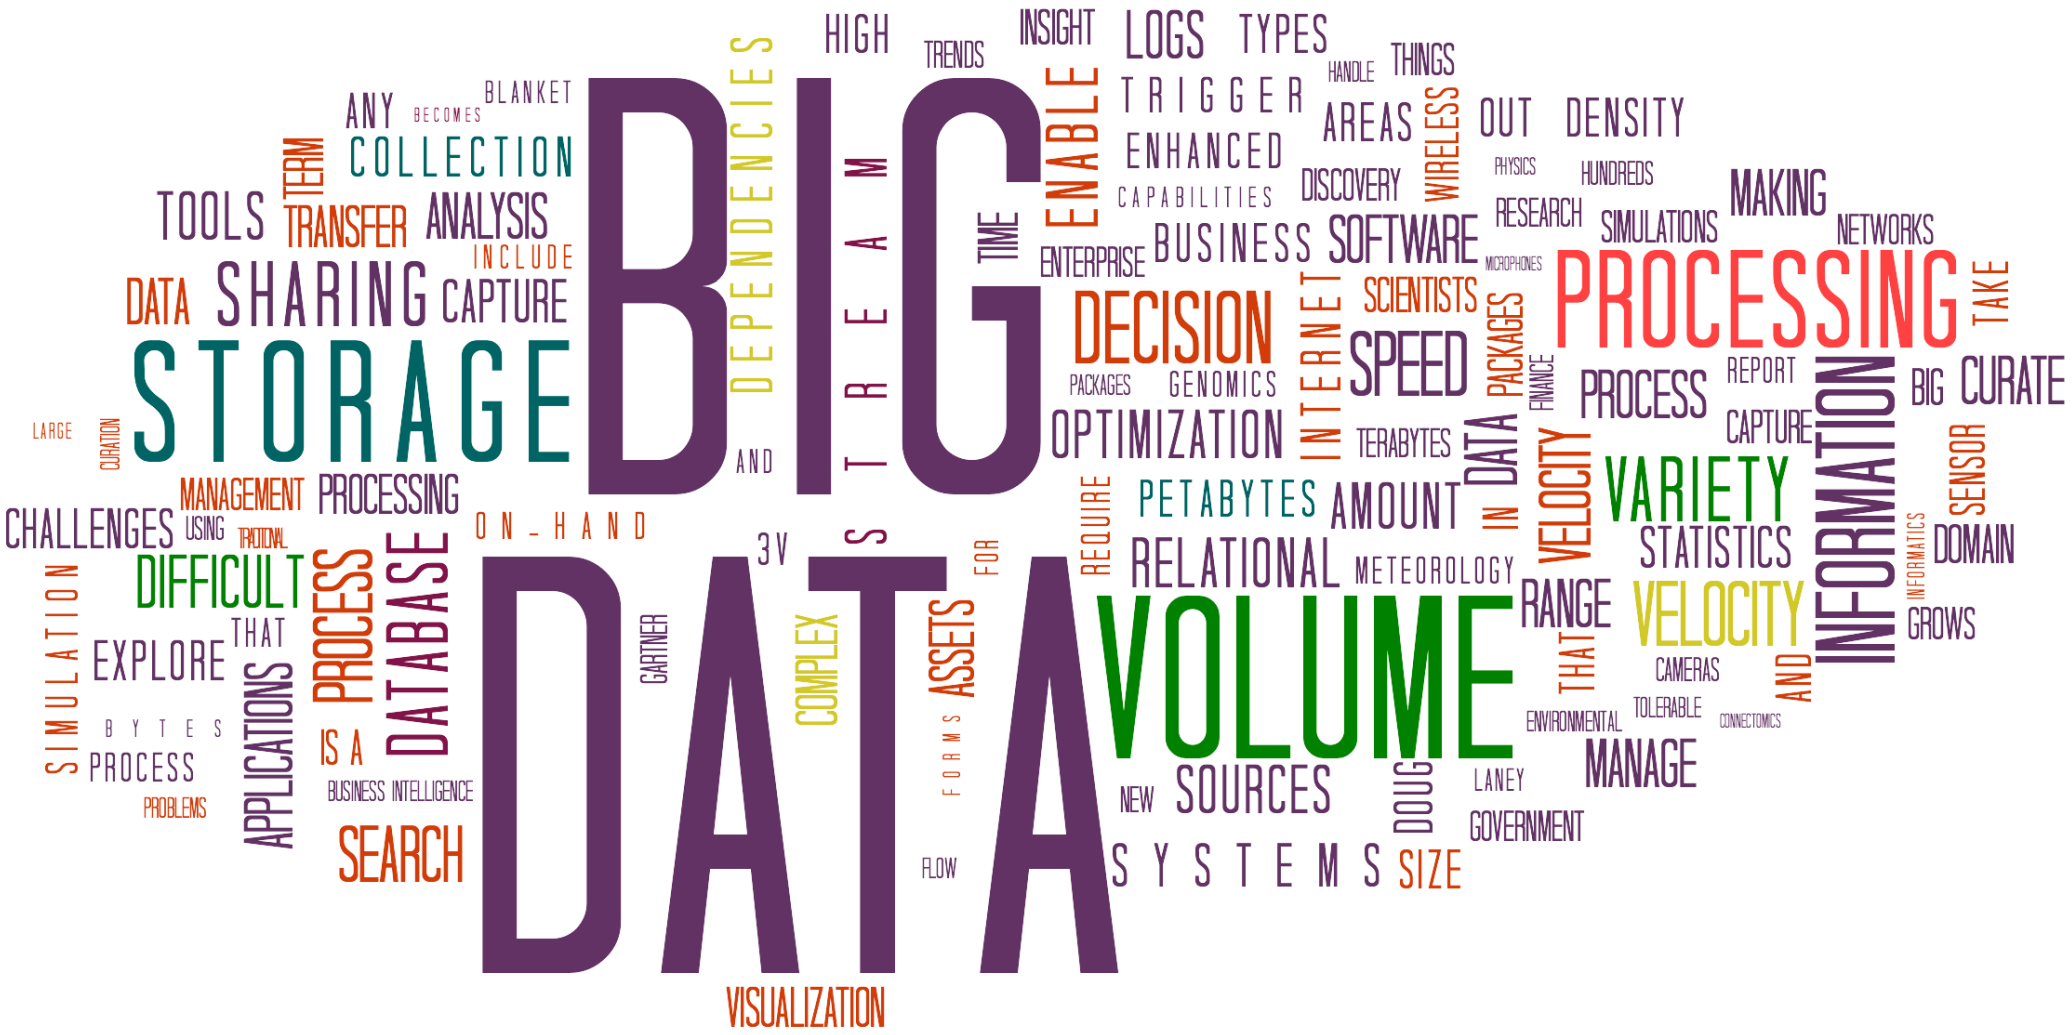

Actors in Big Data Scenarios

Nell'ecosistema dei big data, è possibile identificare, tra gli altri, i seguenti attori principali:

- i *soggetti generatori di dati* (o fornitori di dati);
- i *fornitori della strumentazione tecnologica*, tipicamente sotto forma di piattaforme per la gestione dei dati;
- gli *utenti*, cioè coloro che utilizzano i big data per creare valore aggiunto;
- i *data brokers*, cioè le organizzazioni che raccolgono dati da una varietà di fonti sia pubbliche, sia private, e li offrono, a pagamento, ad altre organizzazioni;
- le *imprese e le organizzazioni di ricerca*, la cui attività diventa fondamentale per lo sviluppo di nuove tecnologie, di nuovi algoritmi attraverso cui esplorare i dati ed estrarre valore;
- gli *enti pubblici*, sia in qualità di enti regolatori dei mercati, sia con riferimento alle attività della pubblica amministrazione volte a migliorare i prodotti e i servizi offerti alla cittadinanza e in grado di aumentare il benessere collettivo.

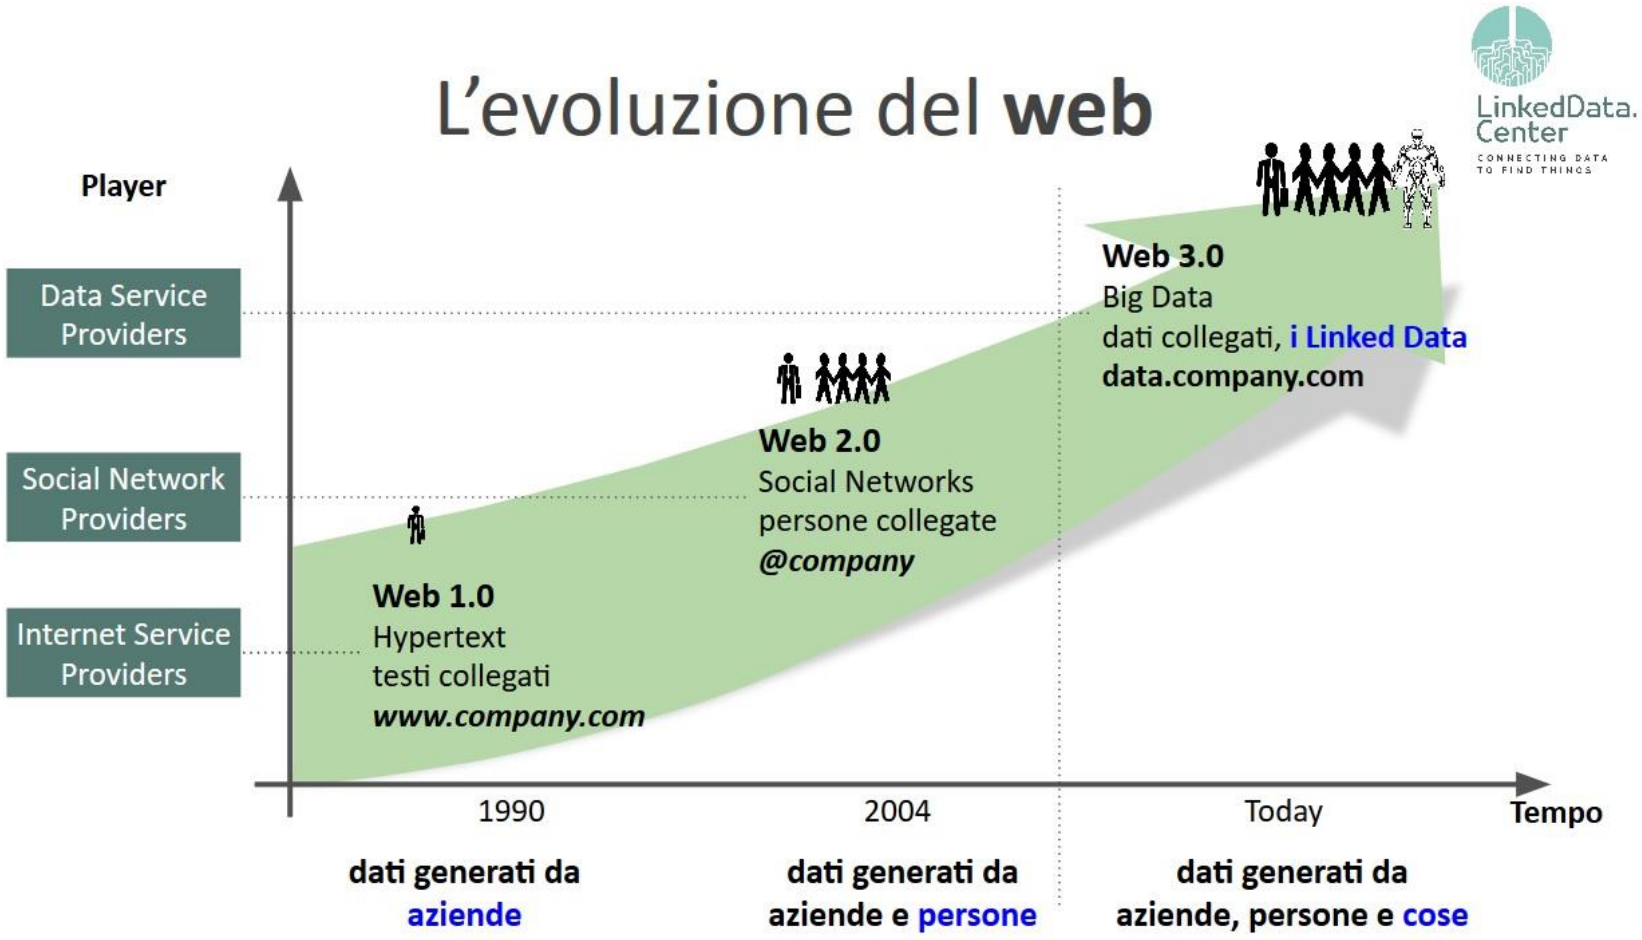

Big Data Ecosystem

Mercato a due versanti

- L'ecosistema dei big data presenta **un grado di interconnessione tra i vari soggetti che vi partecipano tale da rendere difficile l'identificazione di singoli mercati ben definiti**.

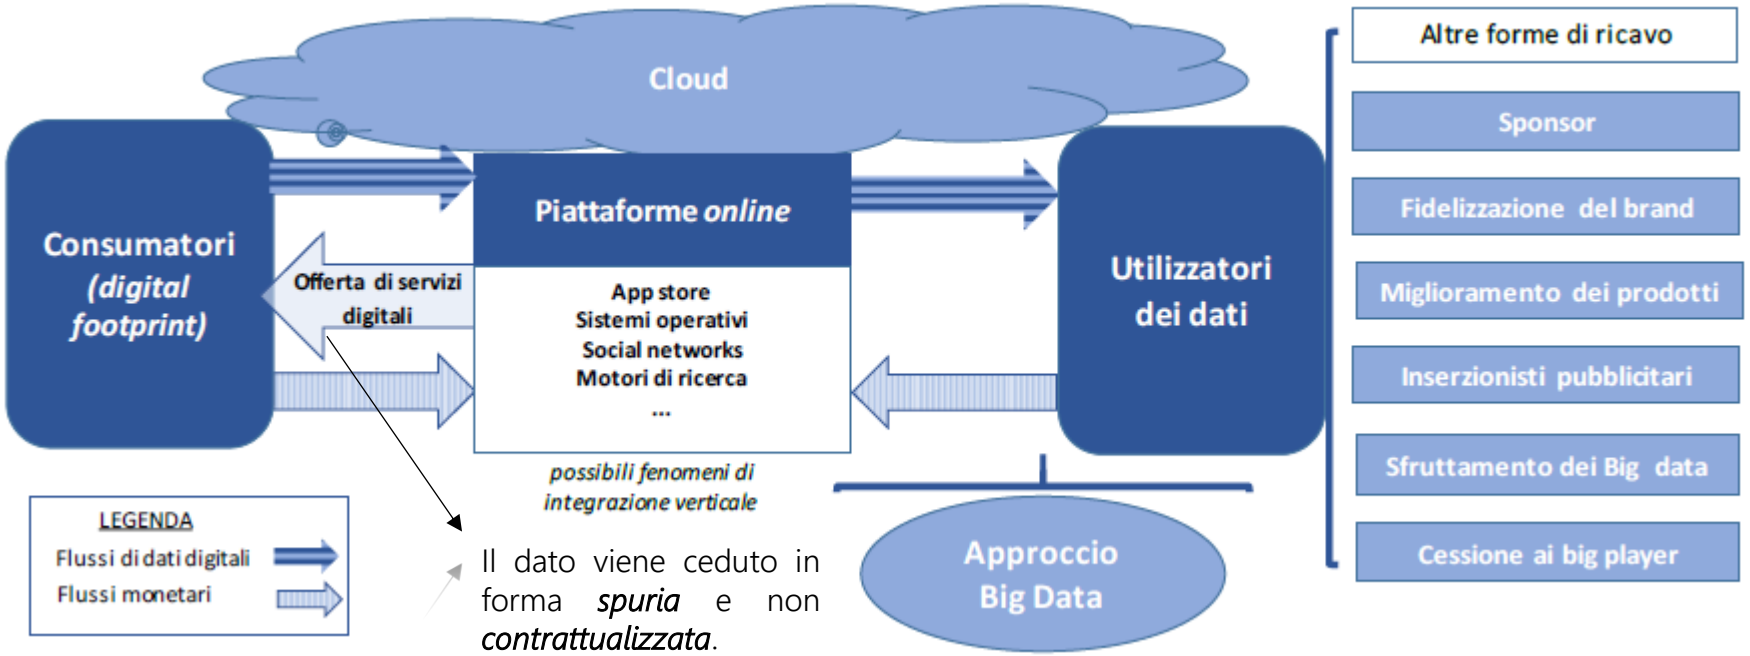

Il dato viene ceduto in forma *spuria* e non *contrattualizzata*.

- **Esternalità di rete dirette**: per i consumatori il valore del servizio aumenta al crescere della rete di consumatori che ne fa uso.
- **Esternalità di rete incrociate**: decisioni prese dagli attori di un lato producono effetti sugli agenti negli altri versanti (*rendimenti di scala che fanno convergere l'ecosistema verso mercati concentrati*).

Entry Barriers

Barriere all'entrata, allo sviluppo e/o all'accesso

- **Fallimenti di mercato** sono legati all'esistenza di barriere all'entrata e allo sviluppo, riscontrabili in tutte le fasi della catena del valore (con natura tecnologica, legale o strategica e possono presentarsi anche contemporaneamente rafforzandosi reciprocamente).
- Un segmento che si evolverà rapidamente sarà quello dei **data center**. Al crescere della dimensione dei dati raccolti, aumenterà la necessità di investire in tecnologie di acquisizione, conservazione e analisi dei dati (es. Posizioni dominanti di piattaforme come Amazon e Google).
- Questi effetti, presentandosi contemporaneamente in molti stadi dell'ecosistema agevoleranno la formazione di **ambiti di mercato fortemente concentrati** (es. Mercato dei SO, dei social network,...).

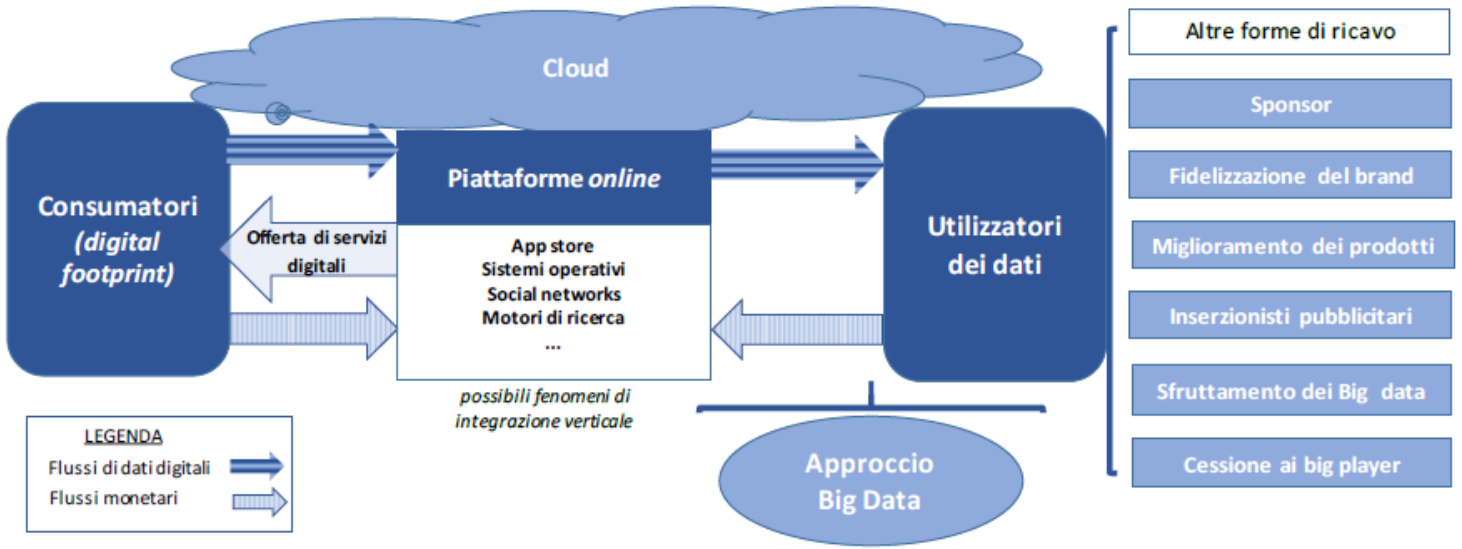

Operating Systems Market

I SO rappresentano un canale privilegiato per la raccolta dati (barriera all'entrata di tipo tecnologico).

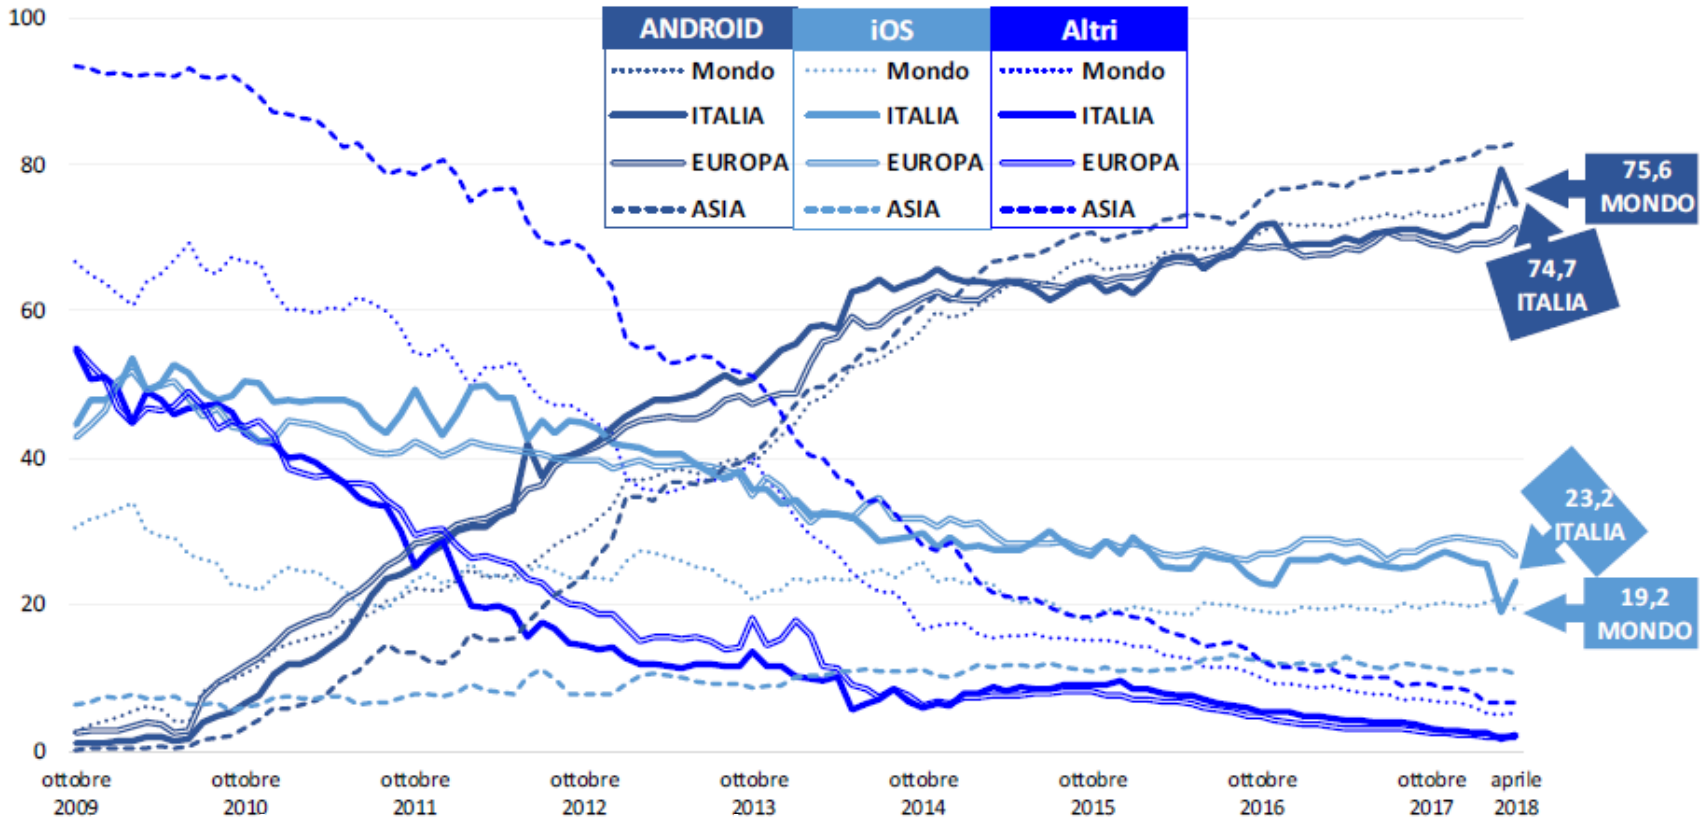

Browsers Market

Si osserva un fenomeno concentrativo in cui si afferma una piattaforma dominante
(evoluzione tipica del imercati in cui prevalgono esternalità di rete).

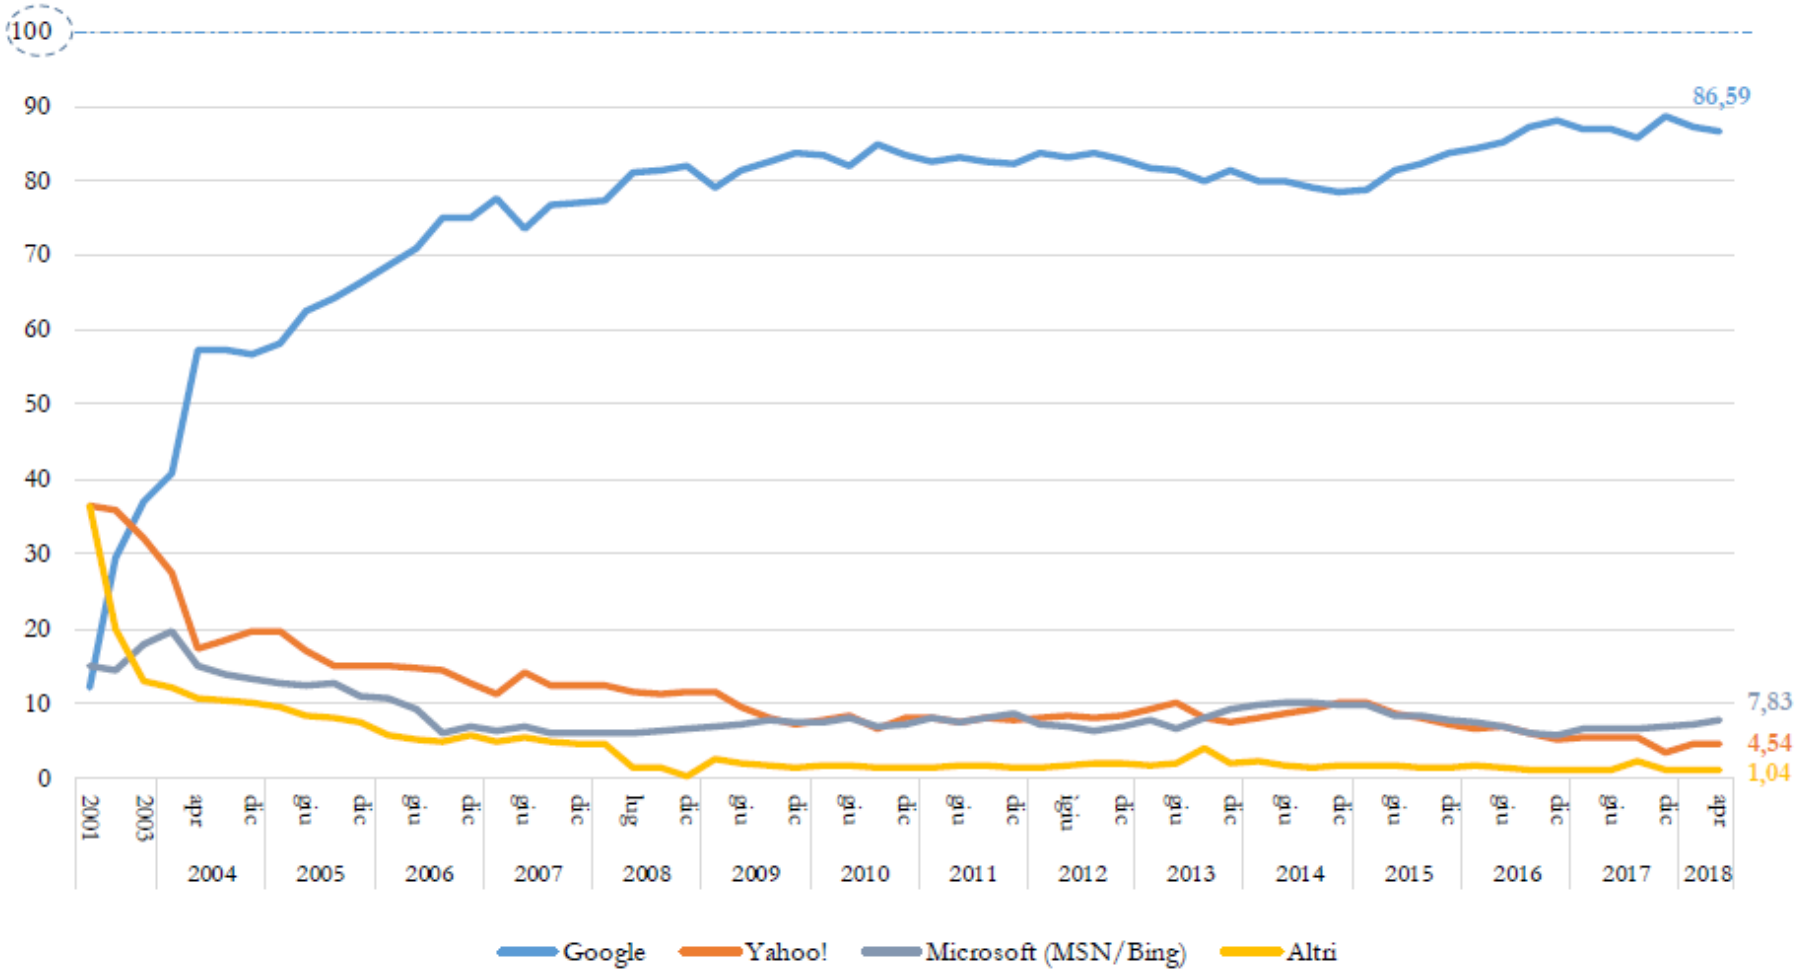

Social Networks Market

Anche nel mercato dei SN, si osserva una dinamica evolutiva simile a quella dei SO.

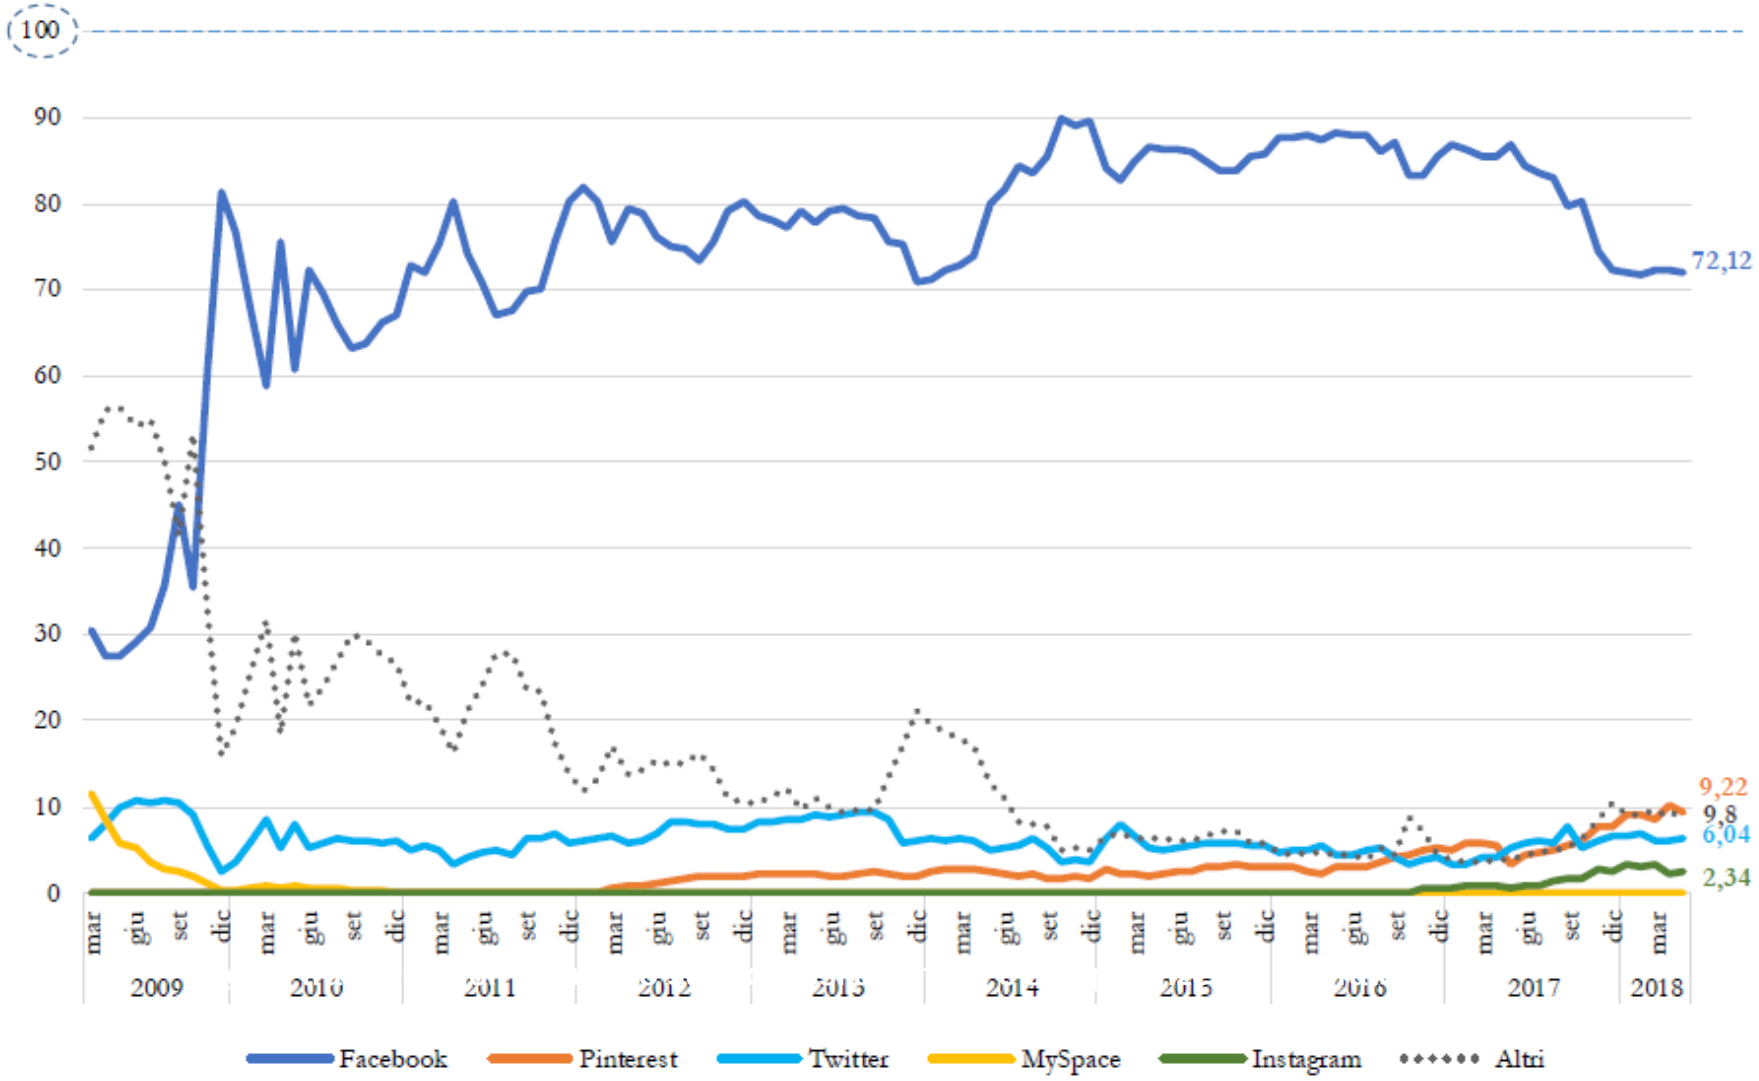

Data Center Evolution

Data Center: infrastrutture materiali che consentono l'attività di acquisizione e immagazzinamento dati.

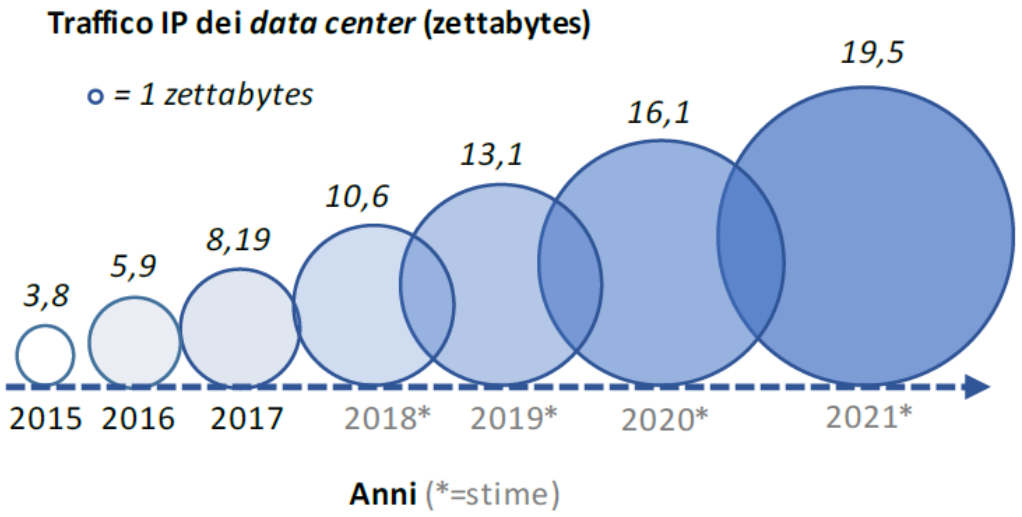

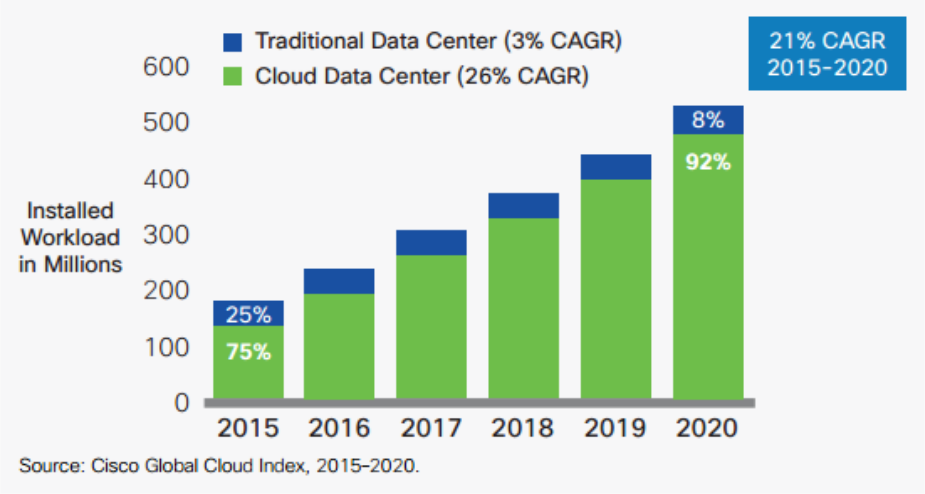

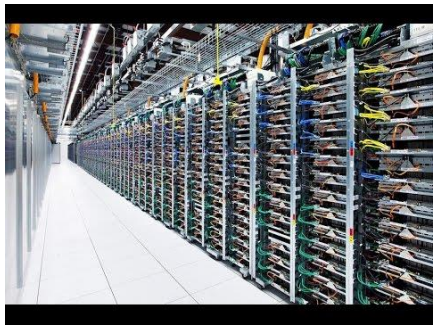

Cloud Provider Market

L'enorme diffusione della Big Data economy e del cloud ha portato modifiche sostanziali nel segmento prima dominato dai data center.

Il mercato mondiale dei servizi di (public) cloud è previsto in crescita del 21.4%, per un ammontare totale di ricavi pari a 186 miliardi di dollari.

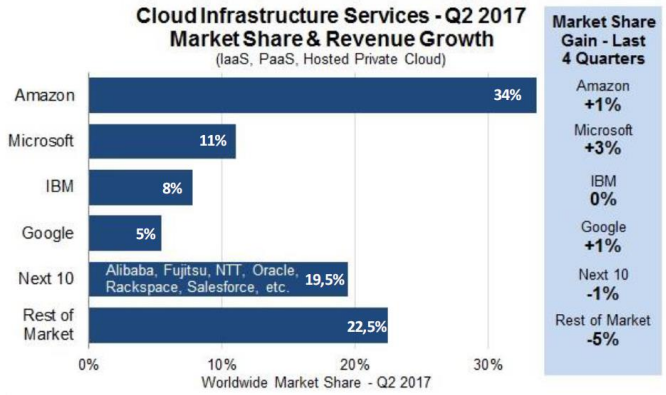

Quote di mercato nei servizi di *cloud* (2° trimestre 2017)
Fonte: https://www.srgresearch.com/articles/leading-cloud-providers-continue-run-away-market

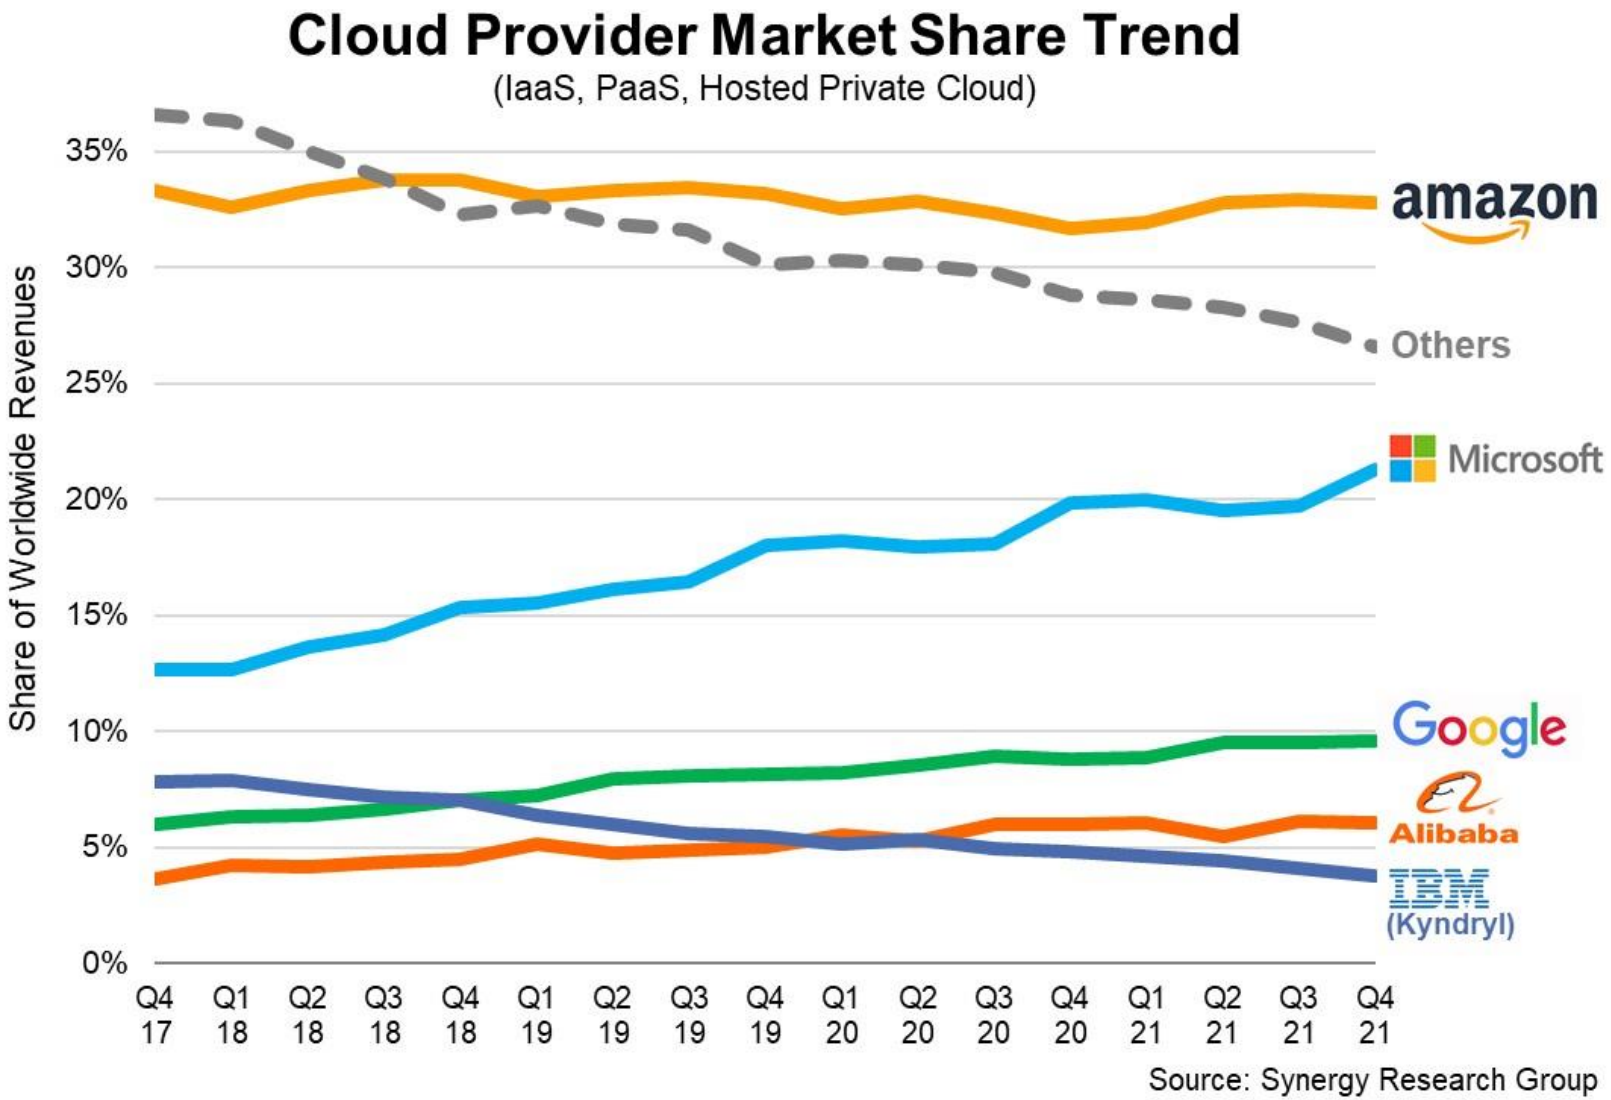

Mobile vs Desktop

- Uno dei principali trend che rende i problemi connessi alla gestione dei dati digitali sempre più rilevante, è la rapida crescita della **fruizione dei contenuti su internet tramite device mobili**.

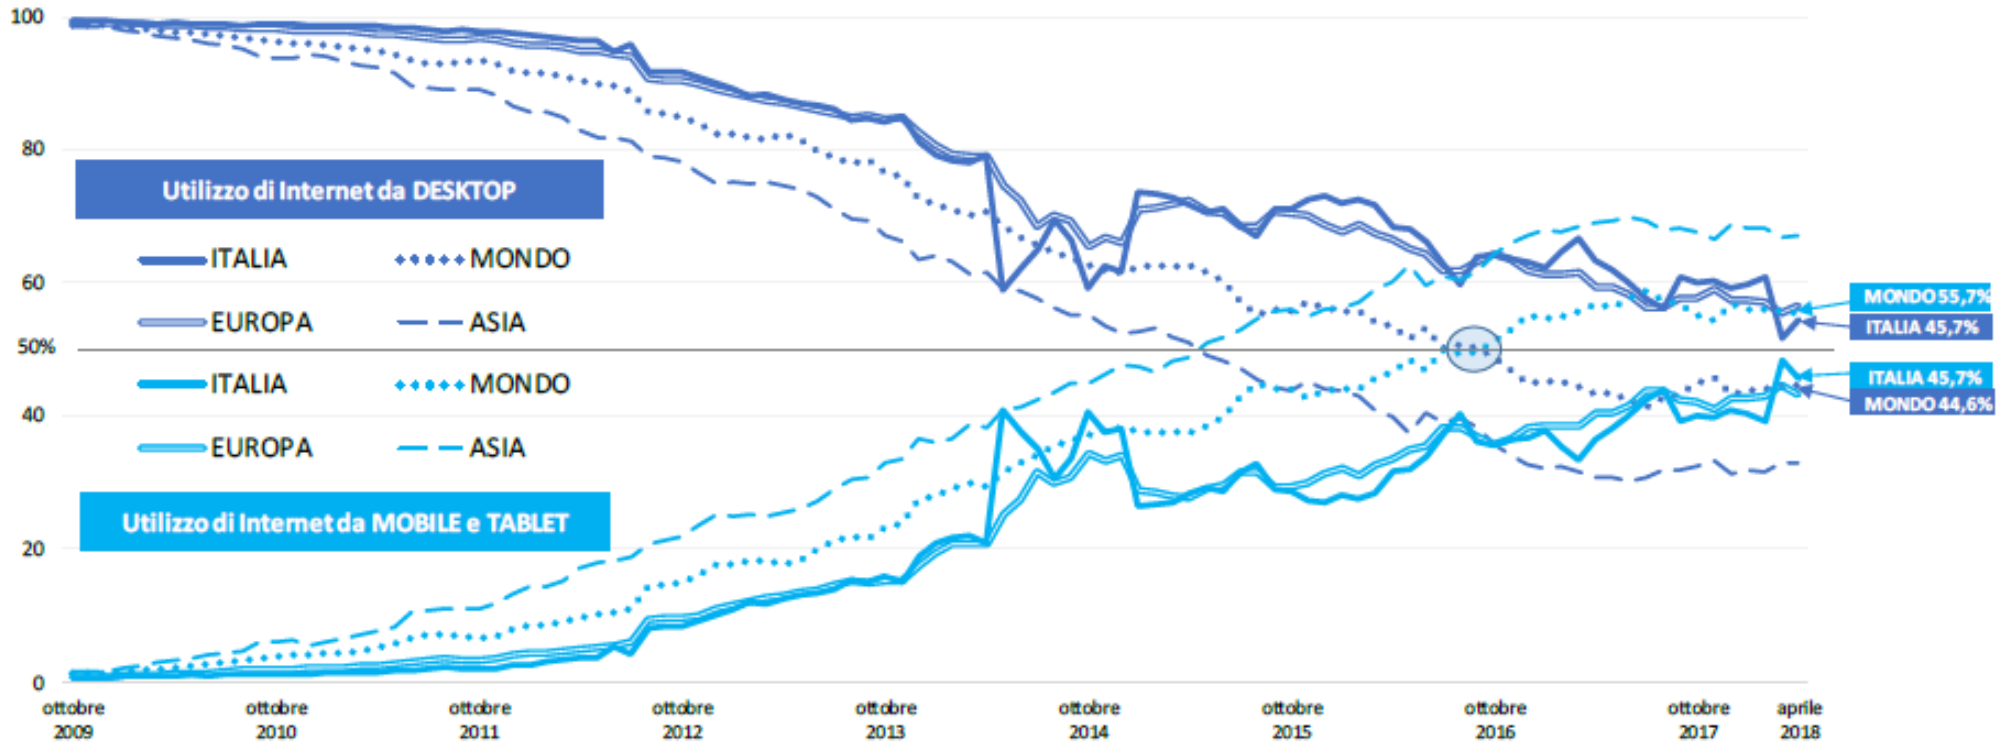

- L'ecosistema delle APP valeva **oltre 1300 miliardi di dollari nel 2016**, mentre per il **2021 il giro d'affari previsto è arrivato a contare oltre 6300 miliardi di dollari**, con una crescita del 385%

Big Data Analytics

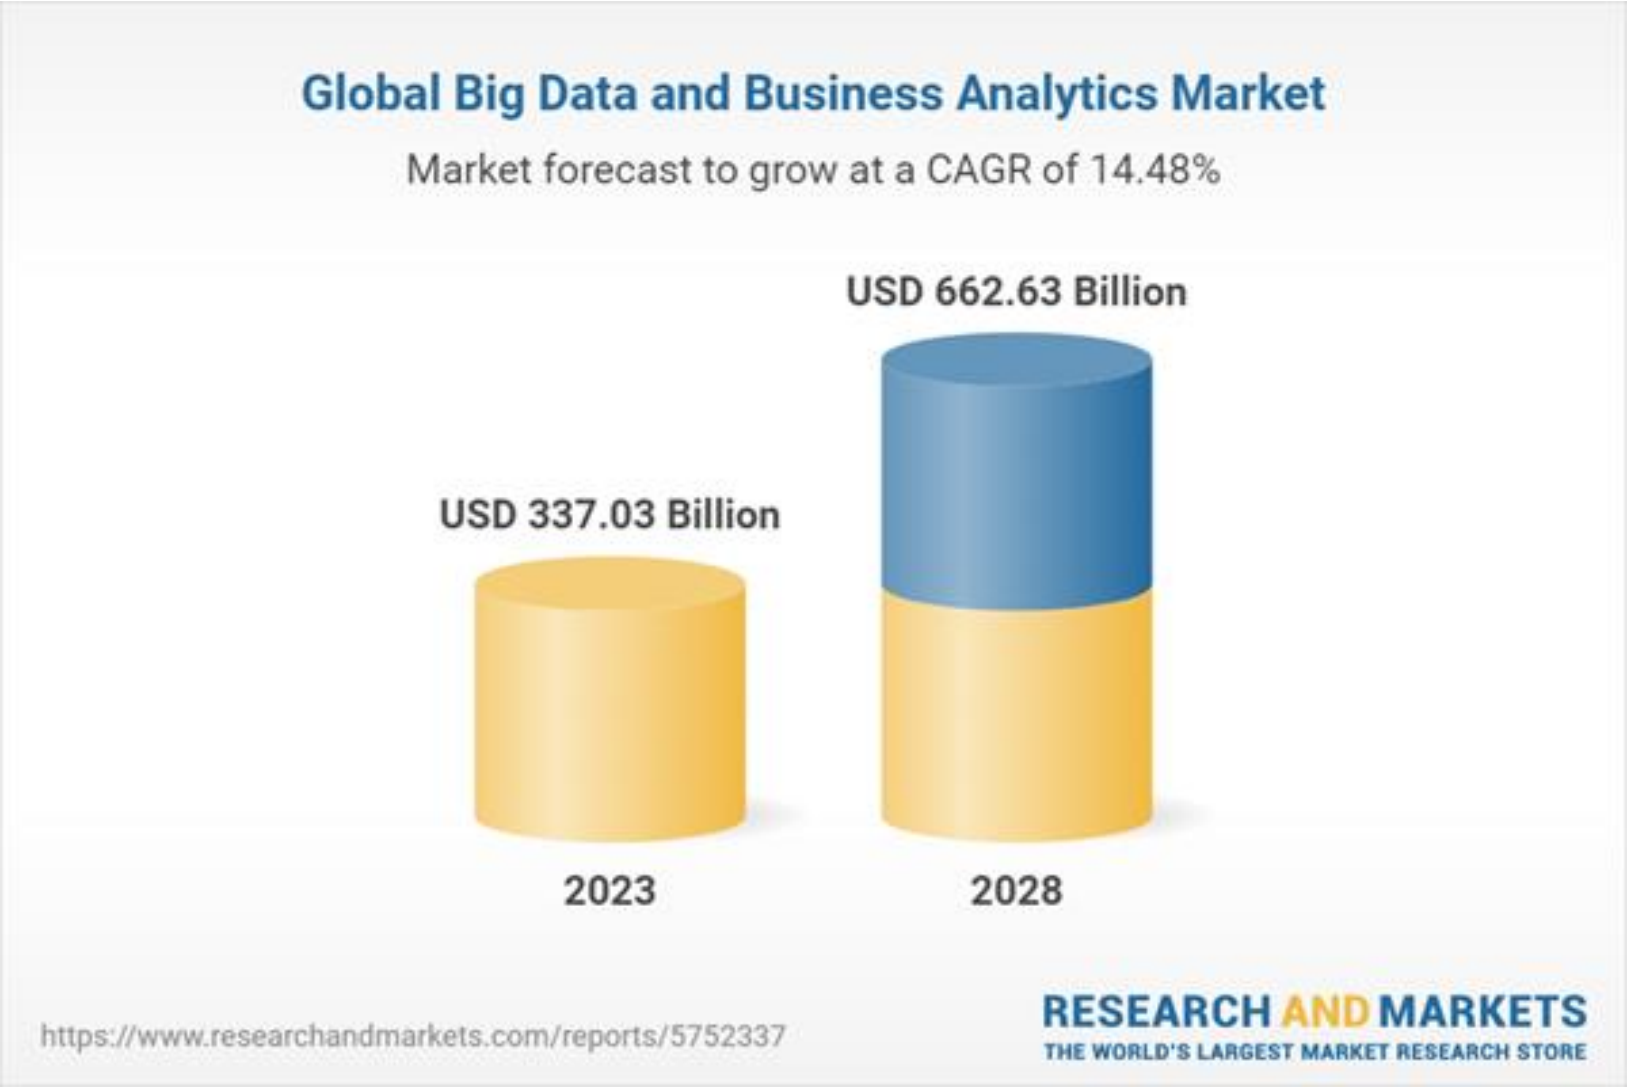

Big Data Analytics nelle aziende

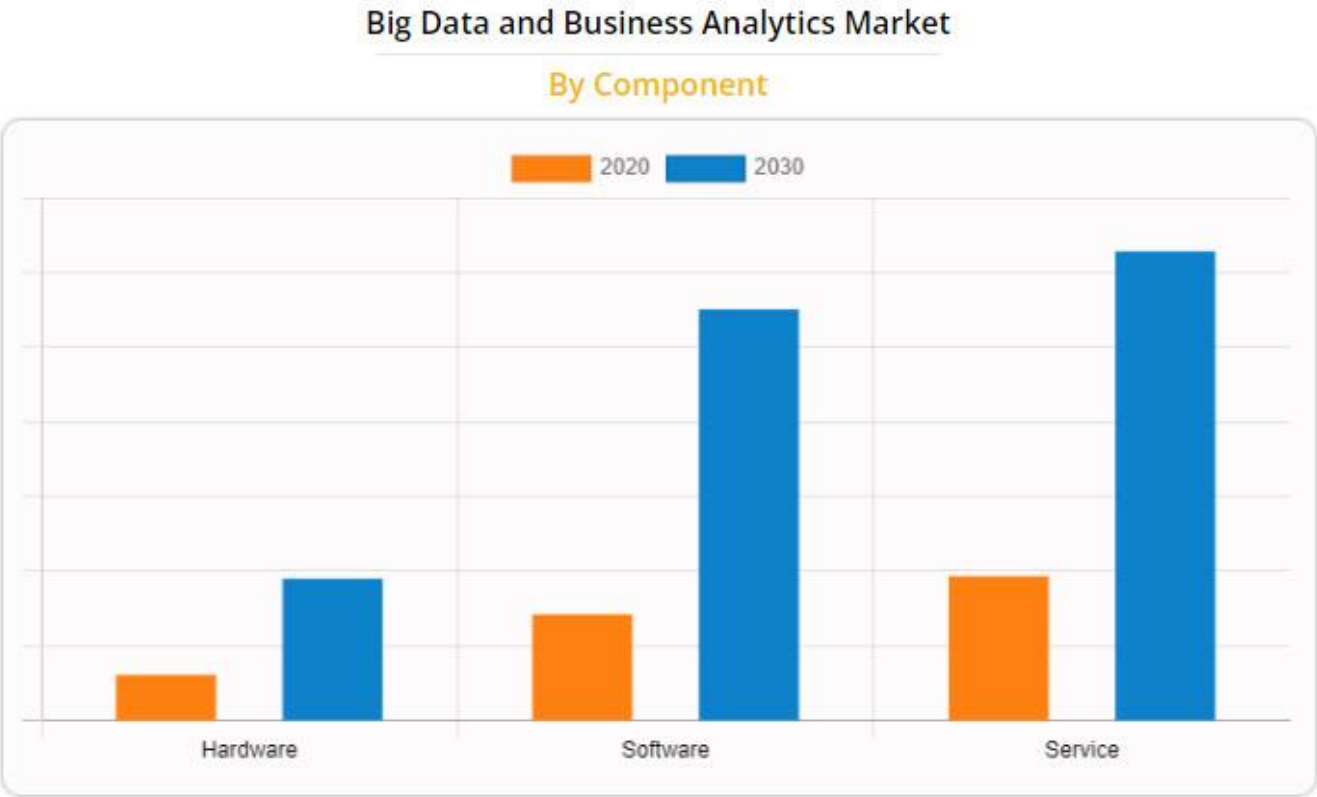

Service is projected as one of the most lucrative segments.

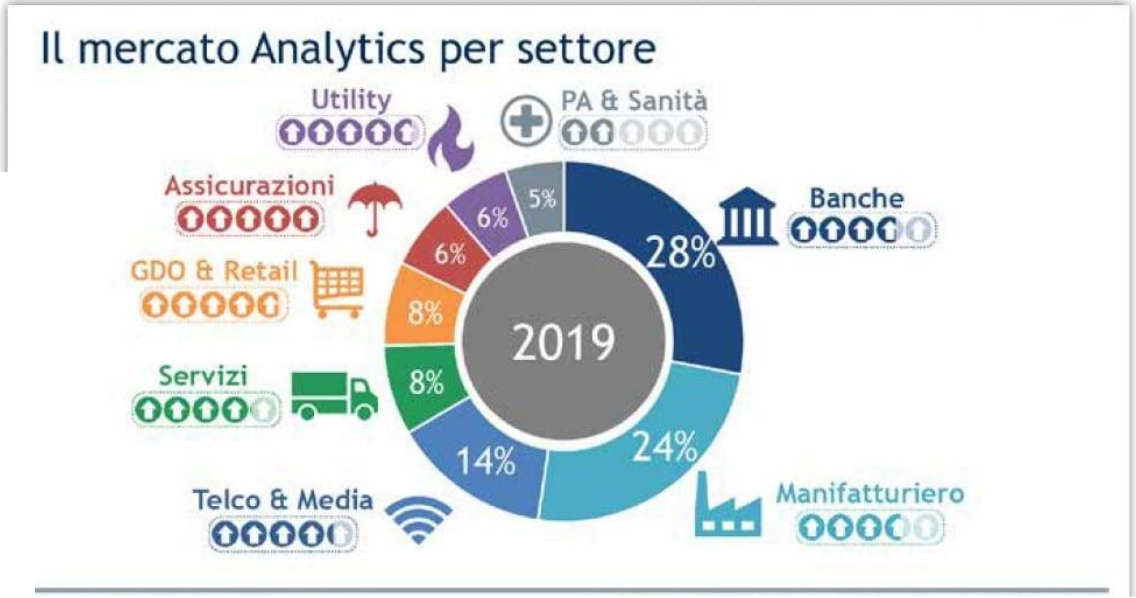

Il livello di digitalizzazione nelle aziende

ROMA TRE UNIVERSITÀ DEGLI STUDI

Il livello di digitalizzazione delle imprese è ancora basso, soprattutto nelle aziende più piccole

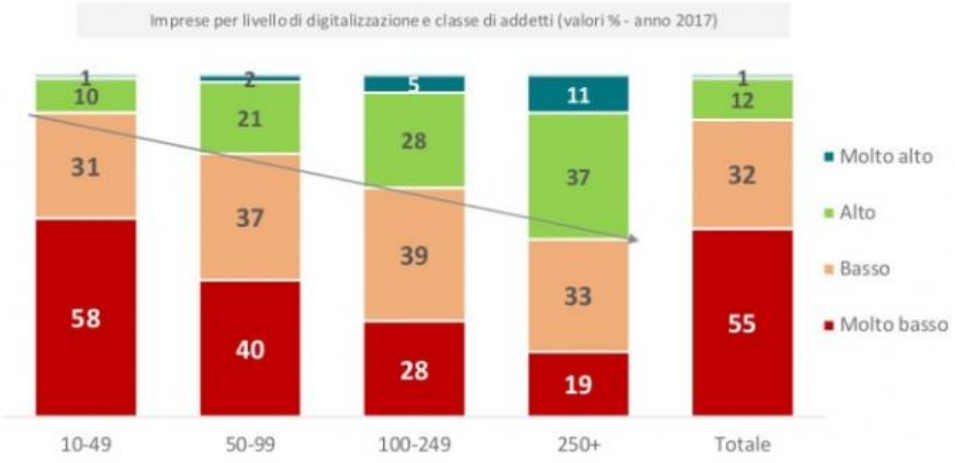

PNRR e post-covid nelle aziende

L'infrastruttura digitale in Italia sta recuperando il gap sul resto d'Europa

Italia: variazioni degli investimenti totali e ICT rispetto al valore del 2008
(indice 2008=100)

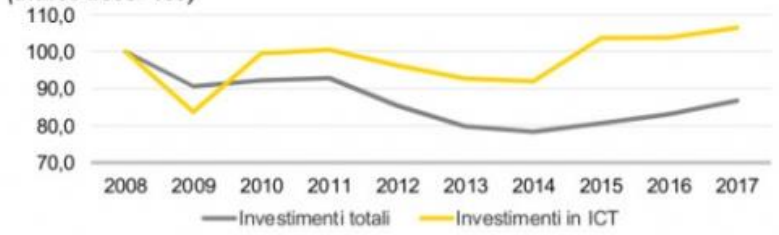

EU15: variazioni degli investimenti totali e ICT rispetto al valore del 2008
(indice 2008=100)

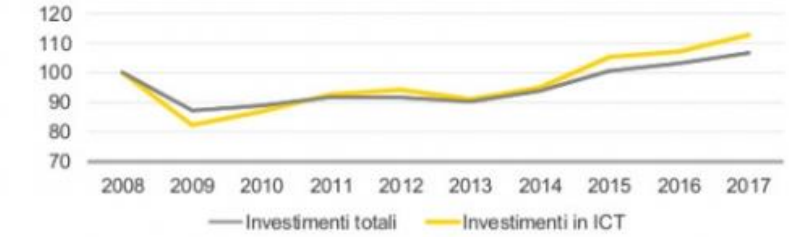

Source: Eurostat

Il trend del budget ICT degli ultimi 10 anni

Startup Intelligence | Digital Transformation
30.11.22
#startupintelligence22
#digitaltransformation22

Rivoluzione digitale e lavoro
Skill shift e nuove professioni

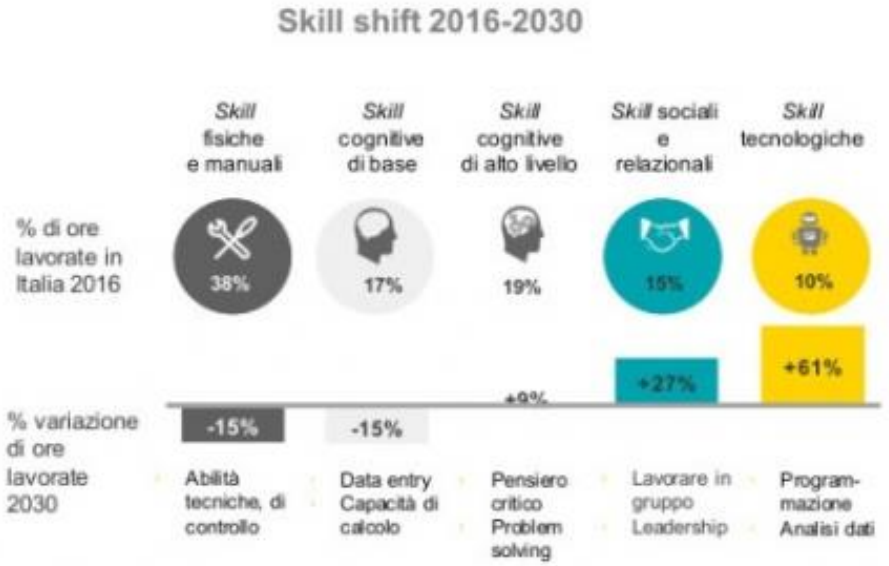

Anche le professioni esistenti cambieranno di contenuto, in termini di **conoscenze**, **competenze** e **mansioni richieste**

Il 65% dei bambini che frequentano oggi la scuola primaria oggi faranno un lavoro **che attualmente non esiste**

World Economic Forum, 2016

Source: 1)Elaborazione EY su dati ANPAL-Unioncamere; 2)McKinsey Global Institute: *Skill shift Automation and the future of the workforce*